武漢理工大學
WUHAN UNIVERSITY OF TECHNOLOGY

算法分析与理论

Principle and Analysis of Computer Algorithms

算法分析与理论--开篇

武汉理工大学
WUHAN UNIVERSITY OF TECHNOLOGY

目录

- 主要讲授内容以及考核方式
- 经典算法在AI时代的应用与发展
- 深度强化学习算法、应用与发展

算法分析与理论--开篇

主要讲授内容以及考核方式

算法的研究目标：

✓ 问题→建模并设计算法	第一层次	算法设计技术
算法→算法复杂度评价		算法分析方法
✓ 算法类→问题复杂度估计	第二层次	问题计算复杂度分析
✓ 问题类→能够求解的边界	第三层次	计算复杂性理论

算法分析与理论--开篇

武汉理工大学 WUHAN UNIVERSITY OF TECHNOLOGY

讲授主要内容

开篇内容：

1）经典算法在AI时代的应用与发展

2）深度强化学习算法、应用与发展

第 1 章　算法及分析基础

第 2 章　动态规划法

第 3 章　回溯法

第 4 章　分支限界法

第 5 章　计算复杂性理论

第 6 章　近似算法

第 7 章　概率算法

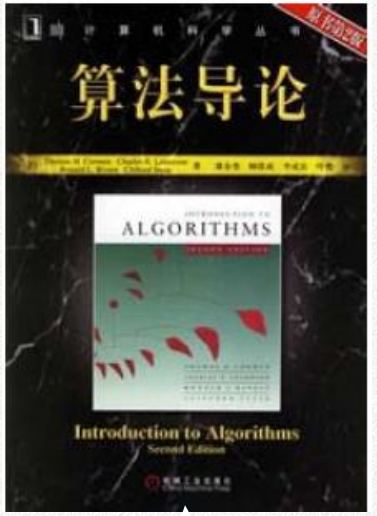


算法分析与理论--开篇

武汉理工大学 WUHAN UNIVERSITY OF TECHNOLOGY

参考书目：

- 《Introduction to Algorithm(Third Edition)》. Thomas H. Cormen. The MIT Press. Cambridge, Massachusetts London, England.
- 《算法导论(第三版)》. 作者: Thomas H. Cormen. 出版社：机械工业出版社. 出版时间：2016.
- 《算法设计与分析（第5版）》. 主编：王晓东. 出版社：清华大学出版社. 出版或修订时间：2018年
- 《算法设计与分析（第3版）》. 主编：王红梅. 出版社：清华大学出版社. 出版或修订时间：2021年.



“计算机算法的圣经”

教学目的

通过本课程的学习：

1.系统的学习和掌握算法设计方法与理论，构建较为完整的算法知识体系；

2.培养对算法和问题计算复杂性进行分析的能力；

3.为独立地设计算法和分析算法奠定坚实的理论基础。

教学方式

线上、线下教学相结合，翻转课堂，创新教学模式：

1、**线上学习：**学堂在线“雨课堂”（登录学校一体化平台网址https://gswhut.yuketang.cn/）：学习“算法分析基础”（部分）、“动态规划法”、”回溯法“、“分支限界法”、“近似算法”、

2、**线下讲授：**经典算法在AI时代的应用与发展、深度强化学习算法应用与发展、“算法分析基础”（部分）、“计算复杂性理论”、“概率算法”

算法分析与理论--开篇

武汉理工大学
WUHAN UNIVERSITY OF TECHNOLOGY





登录学校一体化平台网址https://gswhut.yuketang.cn/（温馨提示：推荐使用Google的Chrome浏览器或火狐浏览器）

考核方式

成绩评定：

- ✓ **平时成绩：40%**

  其中：线上学习（雨课堂）：视频等线上学习---50%

  课堂表现（雨课堂）：10%

  课堂讨论：40%

- ✓ **期末大作业：期末大作业：60%**

课堂讨论要求

1、分组与时间节点：6人一组；第8周周四前提供分组名单与选题（腾讯文档填写），第10周开始讨论；

2、讨论内容：选一种深度强化学习/机器学习/群智能优化算法开展研究，应用其解决一个具体工程问题，包括：工程问题描述、问题建模、算法设计思想与伪码描述、时间复杂度分析、设计对比实验并分析结果、讨论算法局限性以及失败案例等；

3、讨论时间与形式：每组15分钟左右，以PPT+演示形式展示小组分工与研究成果；

4、材料提交：第 13 周末提交全套材料至我的QQ邮箱，包含 PPT、研究报告文档、源码、小组分工；邮件主题写明：成员名单 + 讨论题目。

算法分析与理论

深度强化学习算法：

1.DQN及其改进

2.DPG及其改进

3.DDPG及其改进

4.TRPO算法

5.PPO算法

6.A3C及其改进

7. DreamerV3
8. TD-MPC2
9. CrossQ
10. RLPD;
11. GRPO
12. RLOO
13. DAPO

算法分析与理论

群智能优化算法：

1.粒子群算法及其优化
2.蚁群算法及其优化
3.萤火虫算法
4.蝙蝠算法
5.果蝇优化算法
6.灰狼优化算法
7. 混合蛙跳算法
8.鲸鱼优化算法
9.蝗虫优化算法
10.麻雀搜索算法
11.狼群算法

算法分析与理论

经典机器学习算法：

1.线性回归与逻辑回归（广义线性模型）

2.决策树

3.随机森林算法

4.SVM

5.朴素贝叶斯算法

6.K最近邻算法

7.K均值算法

8.梯度提升算法：Gradient Boosting、GBDT、XGBoost、LightGBM等

9.期望最大算法（EM算法）

算法分析与理论

工程应用问题，如下，但不局限于:

- 无人驾驶 / 移动机器人路径规划问题
- 工业生产中的多机调度优化问题
- 智能电网中的最优功率分配问题
- 智能仓储多 AGV 协同调度问题
- 通信网络动态无线资源分配优化问题
- 工业设备预测性维护与维护决策优化问题
- 港口集装箱岸桥装卸任务调度优化问题
- 电动汽车集群充电调度优化问题

……

经典算法在AI时代的应用与发展

1.经典算法为什么在AI时代仍然重要

- **AI系统需要多种算法协同：** 除模型学习与内容生成外，还涉及数据处理、信息检索、任务规划、资源调度和安全验证。
- **资源约束使算法效率更加重要：** 算力、显存、通信带宽和响应时延，都会影响模型训练与推理的实际效果。
- **经典算法提供分析依据：** 帮助判断求解过程是否正确、计算成本如何增长，以及结果是否具有最优性保证或近似质量保证。
- **经典方法与学习模型可以结合：** 学习模型（如神经网络、大语言模型、强化学习策略网络等）提供预测或候选排序，经典算法负责搜索、约束检查和优化求解。

算法分析与理论--开篇

2. 经典算法与AI应用的三种关联方式

- **直接应用：** AI系统中的具体问题满足经典算法的适用条件，可以直接使用相应算法求解。例如，Viterbi序列解码、背包式模型部署。
- **思想延伸：** 现代AI方法与经典算法共享某些理论或设计思想，但不完全等同。例如，动态规划与Q-learning通过Bellman方程建立联系。
- **系统支撑：** 经典算法用于AI系统的数据处理、检索、部署、调度和验证。例如，RAG文档选择、GPU任务调度。

这三种方式并非同一维度上的互斥分类：“直接应用”和“思想延伸”描述算法与AI问题的关联方式，“系统支撑”描述算法在AI系统中的位置。同一案例可以同时属于直接应用和系统支撑。

算法分析与理论--开篇

3. 分治法在AI系统中的应用与发展

✓ **算法：**将原问题分解为若干规模较小的子问题，递归求解，再合并结果。

✓ **应用：**

- 递归分块矩阵乘法：将矩阵乘法分解为较小的子矩阵乘法，再合并结果。这种分解与合并思想，是神经网络中矩阵乘法类计算（如全连接层、卷积经 im2col 转换后的矩阵乘法）进行并行与分块优化的基础思想之一。
- 树形梯度聚合：分层合并各工作节点或各 GPU 上的梯度，体现分解与合并的思想。
- 分区检索：分别检索各数据分区，再合并候选结果，支撑大规模向量检索。

✓ **发展与延伸：**

在大规模AI系统中，任务划分需要兼顾通信开销、负载均衡和显存占用。数据并行、张量并行与注意力分块体现了相关思想，但不一定属于严格的递归分治算法。

算法分析与理论--开篇

4. 动态规划在AI系统中的应用与发展

✓ **算法：**通过存储子问题的解，避免重复计算，适用于具有重叠子问题和最优子结构性质的问题。

✓ **应用：**

- Viterbi解码：在隐马尔可夫模型、线性链条件随机场等模型中求解最优状态或标签序列。
- CTC前向—后向计算：累加符合给定标签序列的对齐路径概率，支持语音识别等任务的训练。
- 背包式模型部署：在显存需求和部署收益可加、模型可独立选择的假设下，优化部署组合。

✓ **发展与延伸：**

Bellman方程连接了动态规划与强化学习。Q-learning利用交互样本更新动作价值，DQN进一步使用神经网络近似动作价值，二者与动态规划存在理论联系，但不是传统基于已知环境模型的动态规划的直接实现。

算法分析与理论--开篇

5. 贪心算法在AI系统中的应用与发展

✓ **算法：**在每一步选择当前的最优解，以期望得到全局最优解。

✓ **应用：**

- 大模型贪心解码：每一步选择当前条件概率最大的词元，但不保证获得整体概率最大的序列。
- RAG文档选择：在Token预算内，根据相关性、边际信息收益或单位Token收益逐步选择文档。
- 部分迭代式模型剪枝：依据重要性或预计性能损失，逐步选择要删除的权重或通道。

✓ **发展与延伸：**

选择依据由单一得分扩展为相关性、覆盖度、冗余度和资源成本等因素；但贪心策略能否获得最优性或近似保证，仍取决于具体问题结构。

算法分析与理论--开篇

6. 回溯法在AI系统中的应用与发展

✓ **算法：**在解空间树中逐步构造候选解，当部分解无法满足要求时回退并尝试其他分支，可用于寻找一个可行解、所有可行解或最优解。

✓ **应用：**

- Agent工具调用规划：在模拟状态中，搜索满足工具前置条件和任务目标的调用序列。
- 约束文本生成：通过显式回溯，搜索满足关键词、长度和格式要求的候选序列。
- 离散结构配置：搜索满足资源约束的网络结构或模型部署组合。

✓ **发展与延伸：**

可用大模型排序候选，结合约束检查、状态缓存和剪枝提效；但仅搜索部分候选可能遗漏可行解，状态回退也不等于能撤销真实工具操作。

算法分析与理论--开篇

7. 分支限界法在AI系统中的应用与发展

- ✓ **算法：**在解空间树上进行系统搜索、并利用限界条件剪除不可能产生更优解的方法，从而减少无效搜索、提升求解效率。
- ✓ **应用：**
  - 神经网络鲁棒性验证：对不确定的ReLU激活状态进行分支，利用可靠的输出界判断是否满足安全条件。
  - 资源约束部署与调度：搜索模型组合或任务分配方案，优化收益、成本或完成时间。
  - 离散量化配置：在具有明确目标函数且能构造有效目标界的情况下，搜索各层量化位宽组合。
- ✓ **发展与延伸：**

结合更紧的松弛界、启发式可行解和学习式分支选择，可以减少搜索量。

算法分析与理论--开篇

武汉理工大学
WUHAN UNIVERSITY OF TECHNOLOGY

深度强化学习算法、应用与发展

01. 深度强化学习的概念

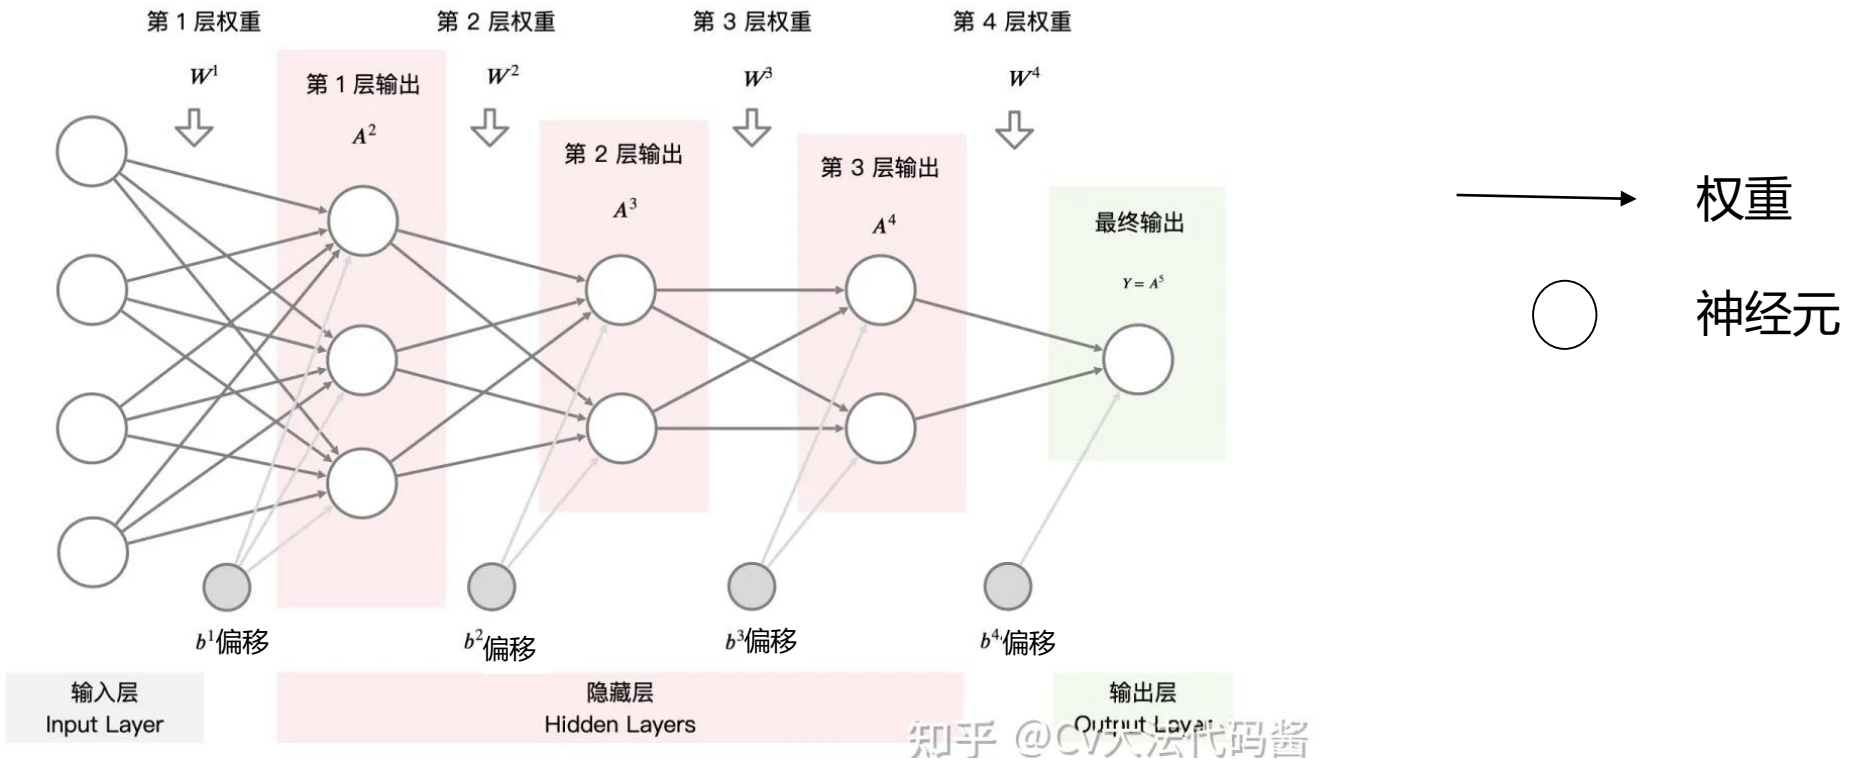
02. 各类深度强化学习算法

03. 深度强化学习算法应用

04. 深度强化学习算法发展

什么是深度学习

深度学习的概念最早由多伦多大学的G. E.Hinton等于2006年提出，基于样本数据通过一定的训练方法得到包含多个层级的深度网络结构的机器学习过程。



神经网络结构

深度学习 vs. 浅层学习

深度学习模型和传统浅层学习模型的区别在于：

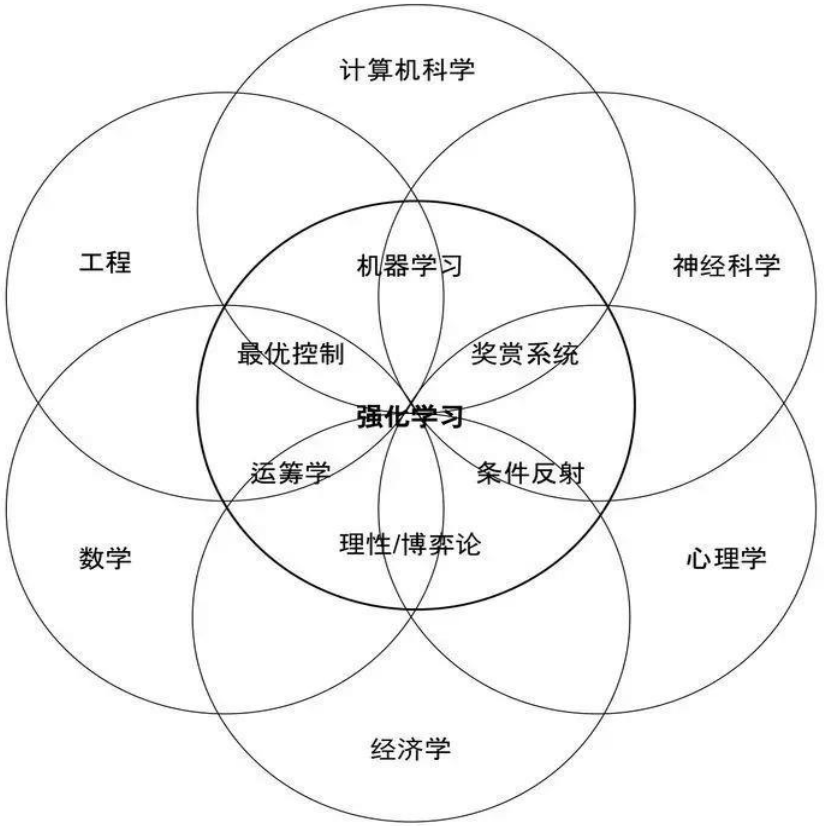
（1）深度学习模型结构含有更多的层次，包含隐层节点的层数通常在5层以上，有时甚至包含多达几十层或上百层以上；

（2）浅层学习依靠人工经验抽取样本特征，网络模型学习后获得的是没有层次结构的单层特征；深度学习通过对原始信号进行逐层特征变换，将样本在原空间的特征表示变换到新的特征空间，**自动地学习得到层次化的特征表示**，使得分类或预测问题更加容易实现。

强化学习

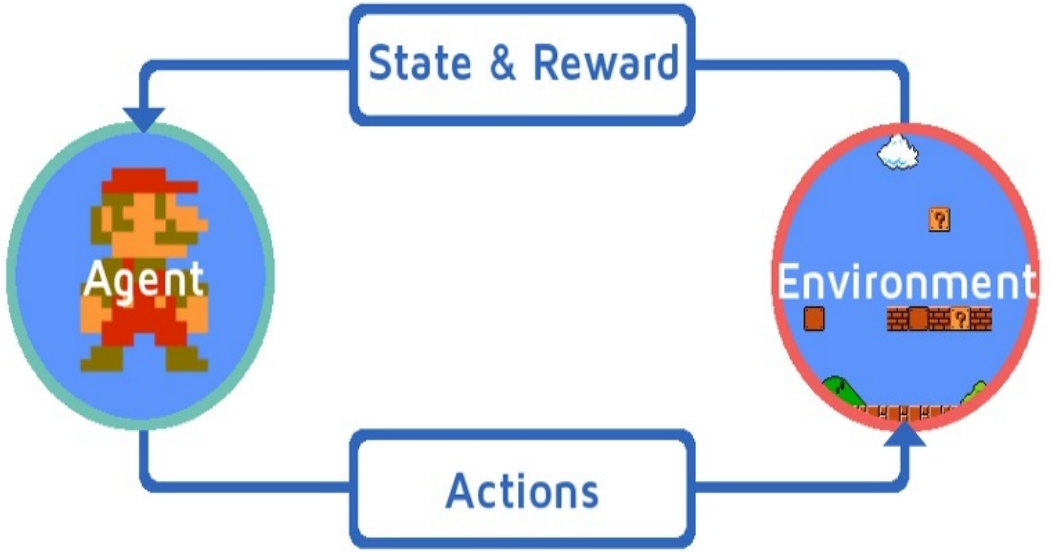
强化学习（Reinforcement Learning， RL），又称再励学习、评价学习或增强学习，是机器学习的范式和方法论之一，用于描述和解决智能体（agent）在与环境的交互过程中通过学习策略以达成回报最大化或实现特定目标的问题。

强化学习是一个交叉学科，与计算机科学、脑神经科学、数学、工程学、心理学、经济学都有密切关系。例如：数学中的Markov决策过程和Bellman方程是其理论基础；工程学中的优化控制提供了动作选择的策略；脑神经科学为DQN算法（一种深度强化学习算法）提供了诸多灵感；经济学的目标同样是根据不完全信息以获取最大化回报，等等。



强化学习

- Agent: 智能体，智能体是指驻留在某一环境下，能持续自主地发挥作用，具备驻留性、反应性、社会性、主动性等特征的计算实体。---主角
- Environment：智能体交互的环境
- State: 智能体所处的环境状态
- Action: 智能体根据所处的环境状态(State)，按照一定的策略(π)而采取的动作(Action)
- Reward: 智能体根据状态(State)，采取动作(Action)后获得的回报



强化学习

强化学习是机器学习的一个分支，具有以下特点：

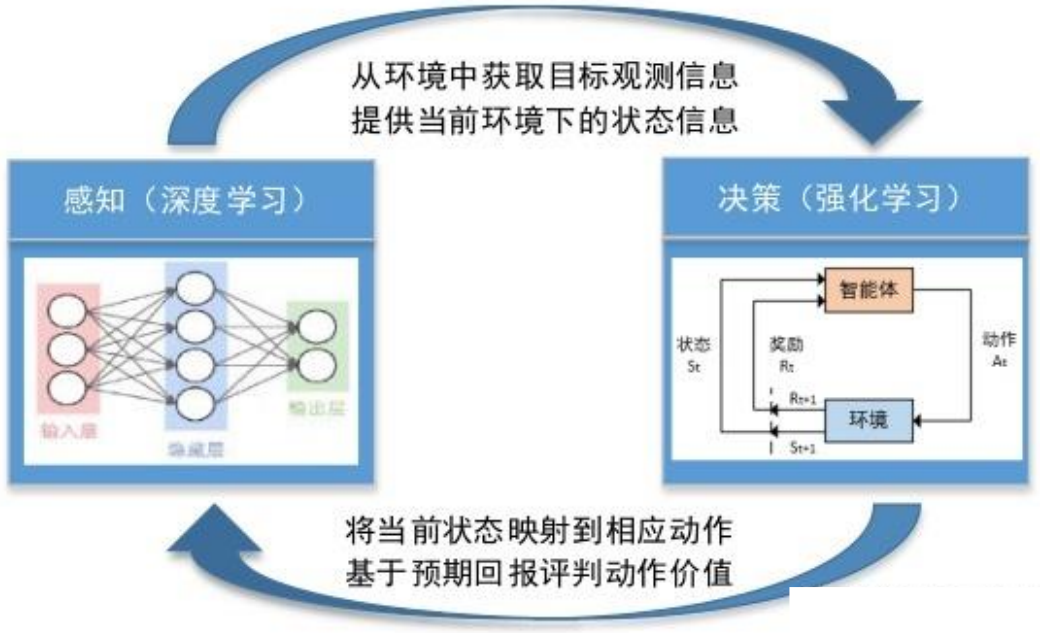
- 无特定数据，只有奖励信号
- 奖励信号不一定实时
- 主要研究时间序列的数据，而不是独立同分布的数据
- 当前行为影响后续数据

深度强化学习

深度强化学习将深度学习的感知能力和强化学习的决策能力相结合，使用强化学习方法定义问题和优化目标，使用深度学习方法解决状态表示、策略表达等问题，通过各取所长的方式协同解决复杂问题，是一种**更接近人类思维方式的人工智能方法**。

解析：强化学习是骨架，深度学习是灵魂。**通过在强化学习计算框架中引入深度神经网络使得智能体能够感知更为复杂的环境状态并形成更为复杂的策略**，由此提高强化学习算法的计算能力与泛化能力。

深度强化学习

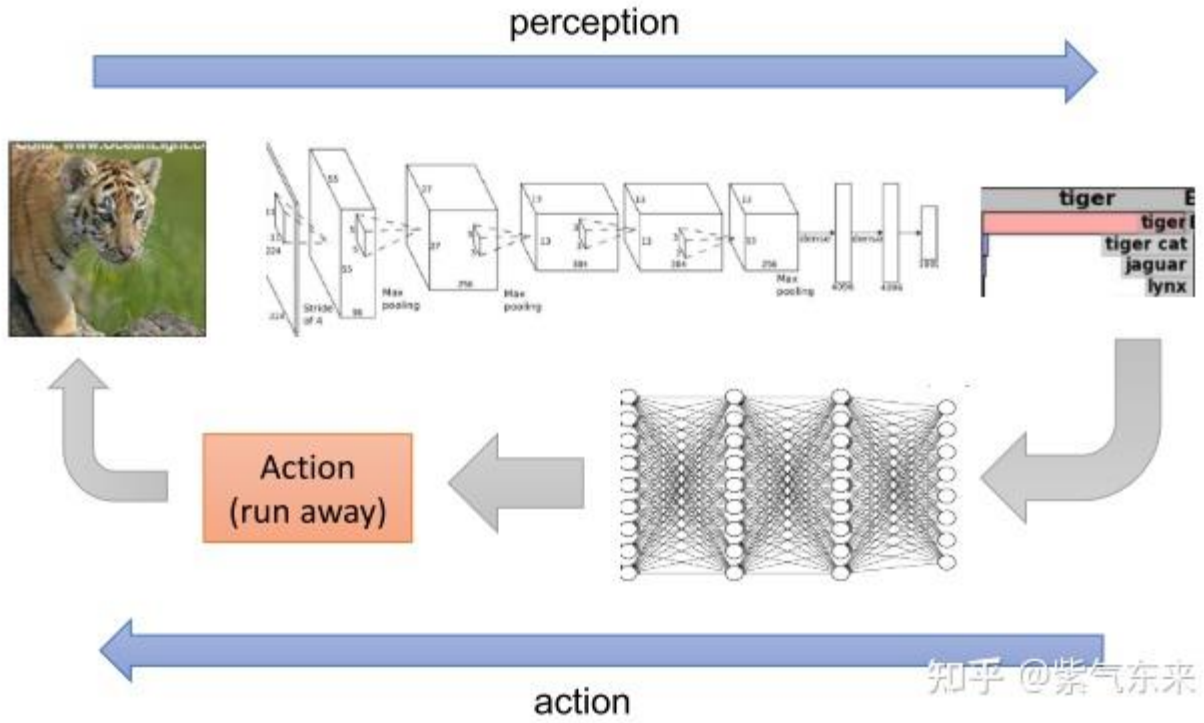


(1)在每个时刻agent与环境交互得到一个高维度的观察，并利用深度学习方法感知观察，以得到具体的状态特征表示；

(2)基于预期回报评价各动作的价值函数，并通过某种策略将当前状态映射为相应的动作；

(3)环境对此动作做出反应，并得到下一个观察。通过不断循环以上过程，最终可以得到实现目标的最优策略。

深度强化学习



上例说明了深度学习和强化学习的关系，即深度学习能够识别图片中的对象，而不会进行任何决策；而强化学习能够在识别对象的基础上进一步提供决策信息。

算法分析与理论--开篇

深度强化学习算法、应用与发展

01. 深度强化学习的概念

02. 各类深度强化学习算法

03. 深度强化学习算法应用

04. 深度强化学习算法发展

各类深度强化学习算法

发展历程



发展历程

DeepMind 是一家位于伦敦、Google旗下 的人工智能前沿技术公司。在深度强化学习历史上具有非常重要的地位。

- 2013 年：DQN 研究展示了从 Atari 游戏原始像素输入中学习控制策略的可能性，推动深度强化学习发展。
- 2015 年：DQN 改进版论文发表于《Nature》，展示了在更多款（总共49款）Atari 2600游戏中，DQN能够达到或超过人类玩家的性能；DDPG 和 TRPO 等方法推动了连续动作控制与策略优化研究。
- 2016 年： DeepMind开发的AlphaGo程序以4：1 击败韩国围棋冠军 李世石，成为近年来人工智能领域少有的里程碑事件；A3C 推动了异步并行强化学习的发展。
- 2017 年：PPO 被提出；AlphaGo Zero 展示了通过自博弈学习围棋的能力。

发展历程

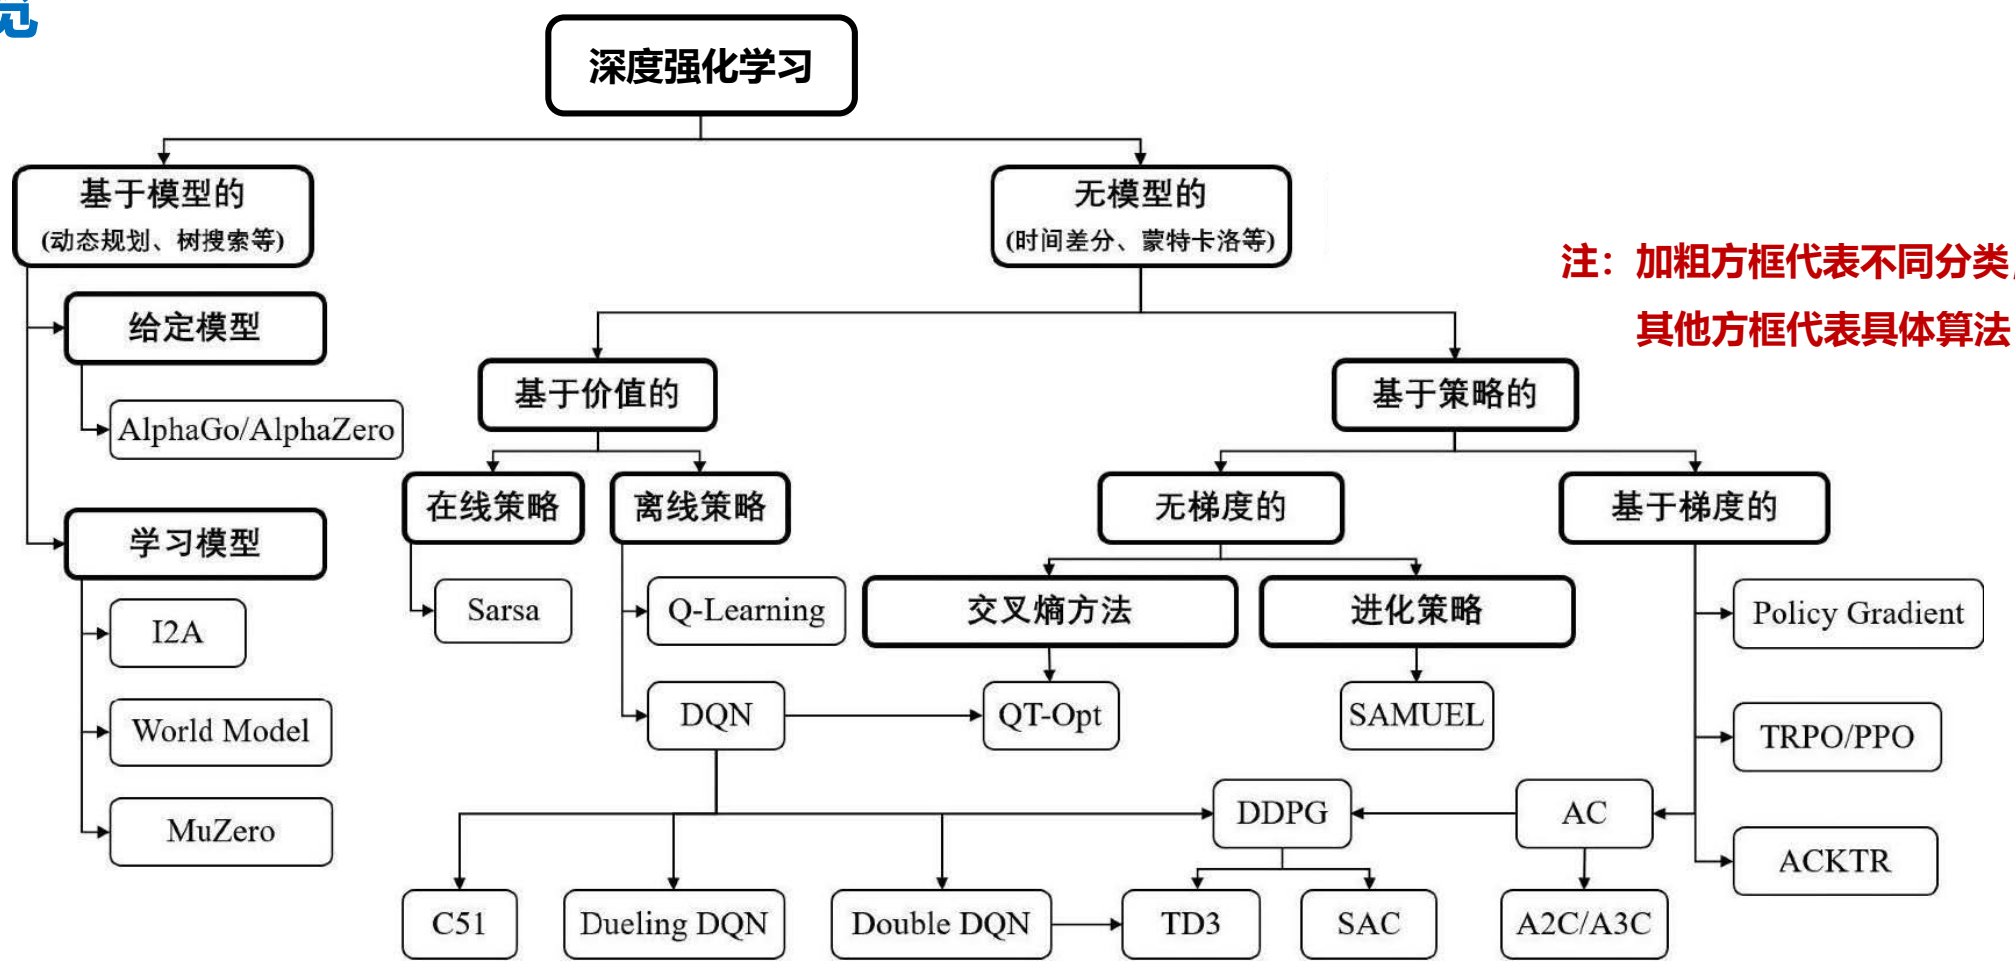
- 2018 年：AlphaZero 相关论文发表于《Science》，展示了同一套方法在围棋、国际象棋和日本将棋中的应用。
- 2019 年：OpenAI Five 击败 Dota 2 职业战队；AlphaStar 在《星际争霸 II》中取得重要进展。
- 2020 年：MuZero 展示了结合学习模型与规划的方法在多种游戏中的表现；离线强化学习受到更多关注。同年，DeepMind发布 “AlphaFold” 系统，参加了如何计算蛋白质分子3D结构的竞赛，并且预测准确性达到前所未有的水平，将“为解决人类50年来的巨大挑战铺平道路”。

发展历程

- 2021 年：Decision Transformer 提出用序列建模方法处理强化学习任务；RLHF 相关研究持续发展。
- 2022 年：ChatGPT 发布，RLHF 成为其训练与对齐过程中的重要方法之一。 同年，DeepMind进一步破解了几乎所有已知的蛋白质结构，为开发新药物或新技术来应对饥荒或污染等全球性挑战铺平了道路。---2024年诺贝尔化学奖：戴米斯·哈萨比斯 和 约翰·江珀
- 2023 年：AlphaDev 展示了利用深度强化学习搜索底层算法的成果。
- 2024 年至今：强化学习持续应用于大模型推理、智能体训练，并在具身智能等方向开展研究。

深度强化学习算法分类

一、分类总览

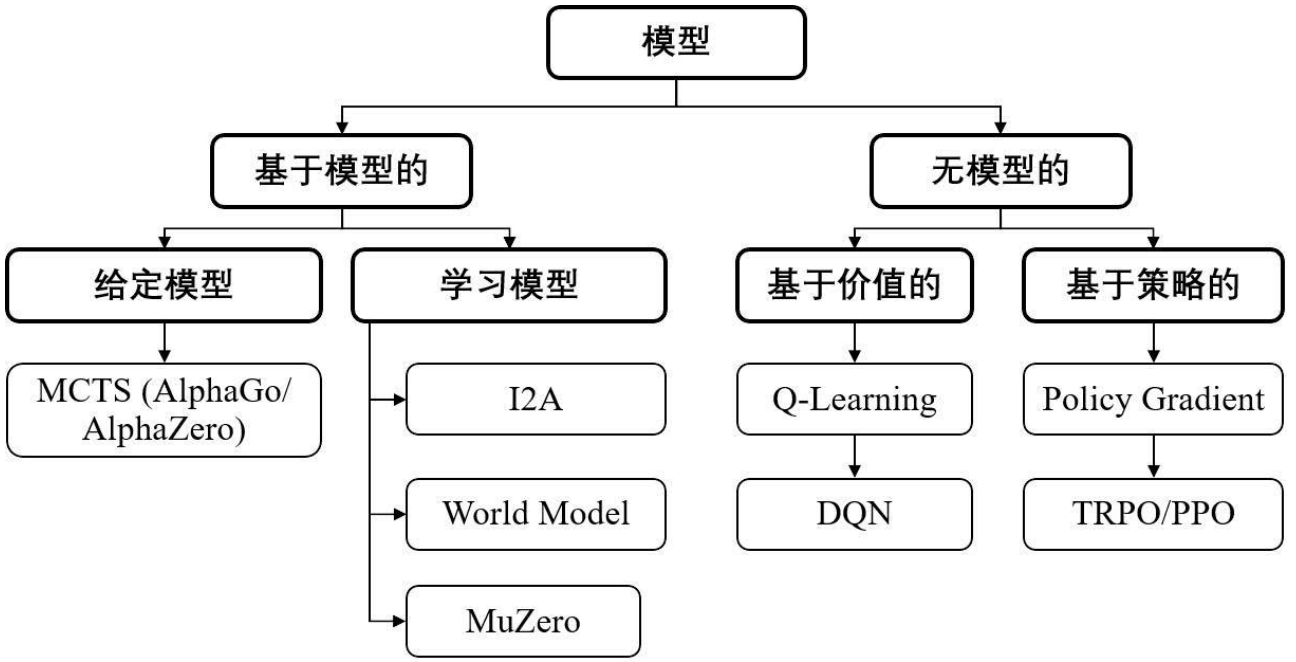


注：加粗方框代表不同分类，
其他方框代表具体算法

深度强化学习算法分类

深度强化学习算法分类（续）

二、基于模型的方法和无模型的方法

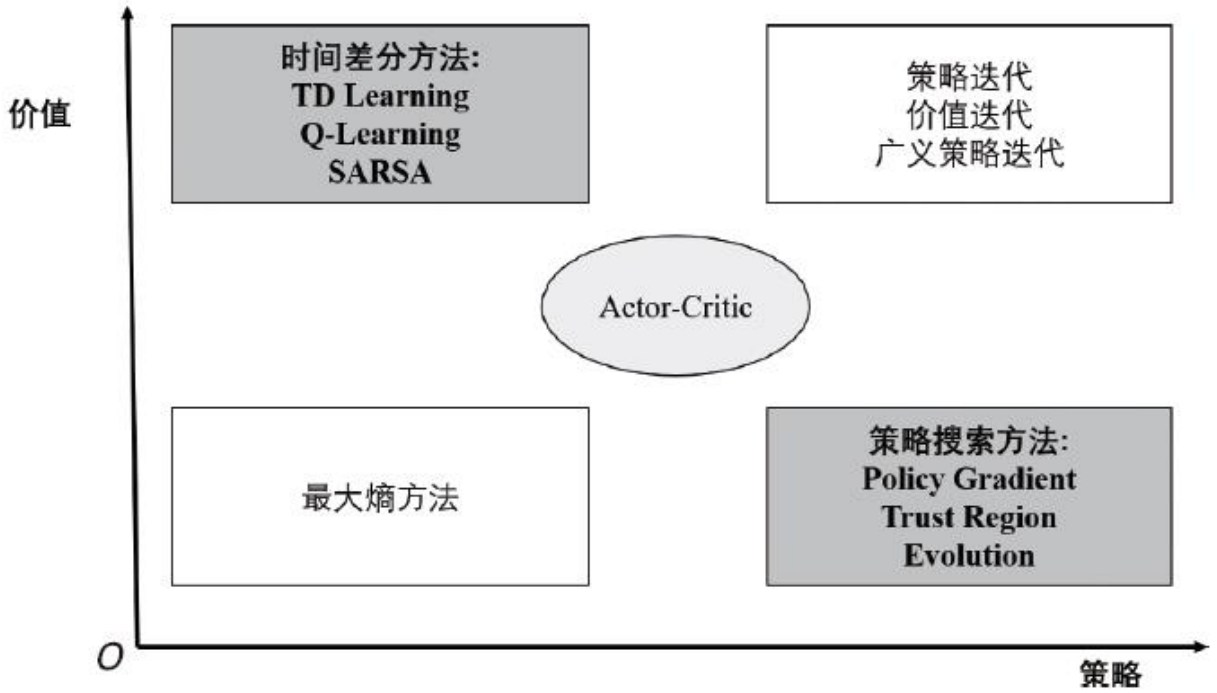


1. **基于模型的方法**（Model-based methods）：这种方法尝试建立一个环境模型，即智能体尝试理解和学习环境的动态性，例如状态转移函数和奖励函数。这种方法的优点是能有效利用每一次的交互学习更多信息，并可以通过模拟或规划来改进策略，从而提高学习效率。然而，缺点是建立准确的环境模型可能很困难，尤其是在环境复杂、信息不全或者环境在不断变化的情况下。这其中最著名的例子就是AlphaZero。

2. **无模型方法**（Model-free methods）：无模型的强化学习方法则直接通过与环境的交互来学习策略或价值函数，无模型方法的优点是它们通常更为简单，且能够在未知或者不确定的环境中工作。然而，由于无法预测环境的变化，这种方法可能需要更多的试验和错误，即更多的样本，才能学到有效的策略。有时在真实环境中进行探索的代价是极高的，如巨大的时间消耗、不可逆的设备损耗及安全风险，等等。

深度强化学习算法分类（续）

三、基于价值的方法和基于策略的方法 →策略优化



基于价值的方法和基于策略的方法（简化版）

典型深度强化学习算法

一、各种经典深度强化学习算法

表 1　深度强化学习算法比较

Tab.1　Comparison of DRL algorithms

算法名称		无模型算法		基于模型的算法	特点	优点	实验环境
		基于策略	基于价值				
DQN	原版[46]		√		目标网络，经验池	减小数据相关性	Atari 2600 游戏
	改进 1 Double DQN[47]		√		解耦动作价值计算和动作选择	解决了价值过高估计	Atari 2600 游戏
	改进 2 Dueling DQN[48]		√		价值函数，优势函数	速率快且收敛效果好	Atari 2600 游戏
	改进 3 C51[49]		√		直接对价值期望建模	提高了学习稳定性	Atari 2600 游戏
	改进 4 QR-DQN[50]		√		分布式，分位数回归	提高了稳定性和精度	Atari 2600 游戏
AC	原版[51]	√	√		集成值函数估计和策略搜索算法	相比值函数算法更快	Atari 2600 游戏
	改进 1 A3C[52]	√	√		异步，多线程	解决 AC 算法难以收敛的问题	Atari 2600 游戏、TORCS 3D 赛车[53]、MuJoCo 仿真器[54]
	改进 2 SAC[55]	√	√		熵正则化	增加探索，加快学习速度	OpenAI Gym 平台[56]
DDPG	原版[40]	√	√		DQN+AC	稳定性高，连续动作空间中表现良好	MuJoCo 仿真器
	改进 1 TD3[57]	√	√		双 Q 网络，“演员”延迟更新，策略平滑化	解决 Q 值高估问题，鲁棒性强	OpenAI Gym 平台
	改进 2 MA-BDDPG[58]			√	动态概率决定数据类型	减小模型数据的负面作用	MuJoCo 仿真器

典型深度强化学习算法

TRPO	原版[59]	√	√		回报函数单调递增	策略优化性能渐进提高	Atari 2600 游戏 MuJoCo 仿真器
	改进 1 PPO[42]	√	√		重要性采样机制，剪切项	在复杂高维度空间中性能优异	MuJoCo 仿真器
	改进 2 ME-TRPO[60]			√	TRPO + 环境模型	限制智能体在未知环境中迭代	MuJoCo 仿真器
	改进 3 SLBO[61]			√	采用多步 L2 范数损失函数训练动力学模型	少样本、高性能	MuJoCo 仿真器
HER[62]			√		附加目标数据和目标奖励	利用次优数据限制探索	OpenAI Gym 平台
I2As[63]				√	想像力机制，预测信息确定当前动作	准确、高效	Sokoba、MiniPacman
MBMF[64]				√	初始化无模型算法学习器	速度快，鲁棒性强	MuJoCo 仿真器
MBVE	原版[65]			√	Q 值短期预测和长期预测结合	Q 值预测更加准确	MuJoCo 仿真器
	改进 STEVE[66]			√	多个候选目标集成获取最优目标，加权求 Q 值	降低一个数量级样本复杂度	MuJoCo 仿真器

典型深度强化学习算法

二、深度Q 网络算法及其改进

1、DQN算法

强化学习的经典Q 学习算法和神经网络结合形成DQN（deep Q network）算法，有效地解决了Q 学习算法计算效率低和数据内存受限的问题。

如图2 所示。DQN 算法的网络结构由目标网络和估计网络组成，这2个网络的结构相同但参数不同。估计网络具有最新的网络参数，计算当前状态-动作对的价值，并且定期更新目标网络的参数，使其计算目标Q 值。双网络结构打破了数据之间的相关性，使得DQN 算法具有更好的泛化性。经验回放部分储存了智能体历史行为信息，打破了经验池中数据相关性和非静态分布问题。

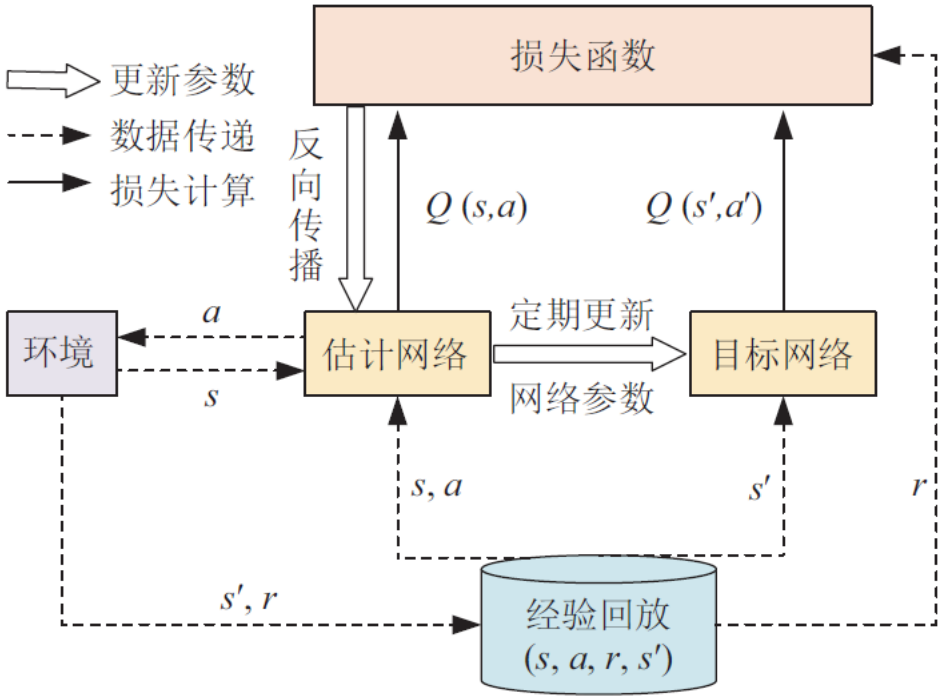


图 2　DQN 算法结构示意图

2、DQN算法的改进

- Double DQN（DDQN）算法

该算法解耦动作价值计算和动作选择。相比于DQN算法，DDQN 算法首先通过估计网络选择最大Q值对应的动作，然后利用该动作在目标网络中计算目标Q值。DDQN 算法有效地解决了DQN 算法过度估计的问题。

- Dueling DQN 算法

优化了DQN 算法结构。该算法将网络分成价值函数和优势函数两部分。价值函数仅与状态有关，与具体采取的动作无关；优势函数与状态和动作都有关。Dueling DQN 算法将价值函数和优势函数的线性组合作为最终输出，相对于DQN 算法具有较强的表达能力。

典型深度强化学习算法

- C51（categorical 51-atom DQN）算法

直接对价值的分布进行建模，采用KL 散度（Kullback-Leibler divergence）作为损失函数。不同于DQN 算法直接对价值期望建模，C51 算法对价值的分布进行建模，其优势是提高了学习稳定性，而且近似分布也降低了基于非平稳策略开展学习所造成的影响。

- QR-DQN（quantile regression DQN）算法

作为C51的延展版，该算法通过损失函数拟合价值的分位数，进行反向传播计算，其稳定性和精度均优于传统的DQN 算法。

三、行动者-评论家算法及其改进

1、AC算法

行动者-评论家（actor-critic，AC）算法的原理是行动者部分通过探索环境生成动作集合，然后根据动作概率函数选择动作；评论家部分负责评估行动者的动作；行动者根据评论家的评分优化动作概率函数，最终指导智能体选择最优动作。行动者-评论家算法的结构示意图如图3 所示。AC 算法采用时序差分误差为评估点，评论家根据估计动作值和实际动作值的均方差更新网络参数。

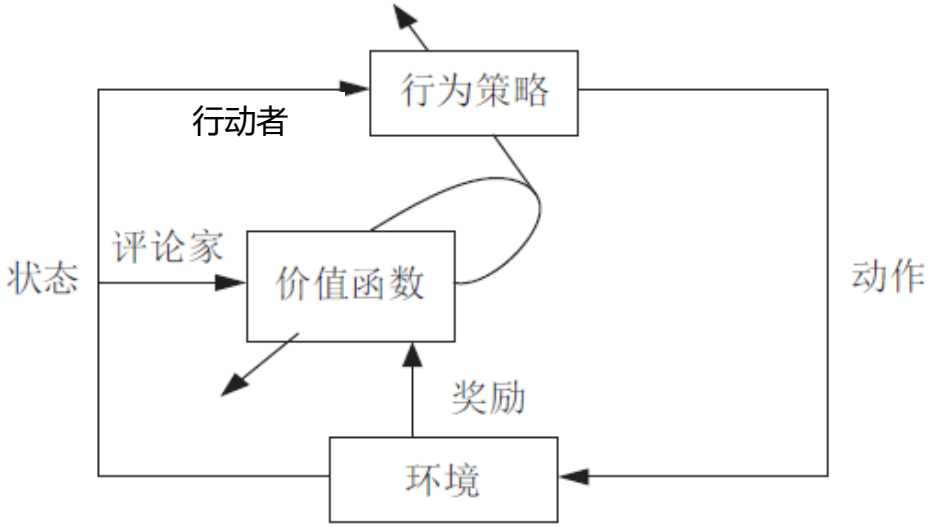


图 3 AC 算法结构示意图[51]

2、AC算法的改进

- A3C（asynchronous advantage actor-critic）算法

相对于AC 算法的改进包括训练框架异步化、网络结构优化以及评估点优化等。A3C 算法借鉴DQN 算法的经验回放并利用多线程的方法，使多个智能体同时与环境进行交互，并将智能体的学习数据汇集到公共空间，以使得每个智能体都能从公共空间采样并共享数据，指导自身的策略学习，解决了AC 算法难以收敛的问题。

- SAC（soft actor-critic）算法

当今最有效的无模型算法之一，通过最大熵方法保证算法的稳定性和有效性。在SAC 算法中，行动者同时最大化期望和策略分布的熵，并且在选取最优行为的同时保证行为策略的随机性。相对于AC 算法，SAC 算法高效且稳定，对不同环境具有更强的鲁棒性。

四、深度确定性策略梯度算法及其改进

1、DDPG算法

2017年，Lillicrap 等在确定性策略梯度（deterministic policy gradient，DPG）算法基础上， 借鉴DQN 算法和AC 算法的思想，提出了DDPG （deep deterministic policy gradient）算法，其结构示意图如图4 所示。

DDPG 算法的网络结构分为评论家模块和行动者模块，包含了4个神经网络。评论家模块采用时序差分误差（TD-error）的方式更新网络参数ω，并且定期复制ω 到目标网络。行动者模块采用DPG 算法的方式更新网络参数θ ，并且行为策略根据其策略网络的输出结果来选择动作作用于环境。DDPG 算法与DQN算法、AC算法相比具有良好的稳定性，而且能够处理连续动作空间任务。但是DDPG 算法对超参数的变化很敏感，需要经过长时间的参数微调才能实现较好的算法性能，而且评论家的Q函数存在高估Q 值的问题，会导致行为策略学习不充分，收敛到非最优状态。

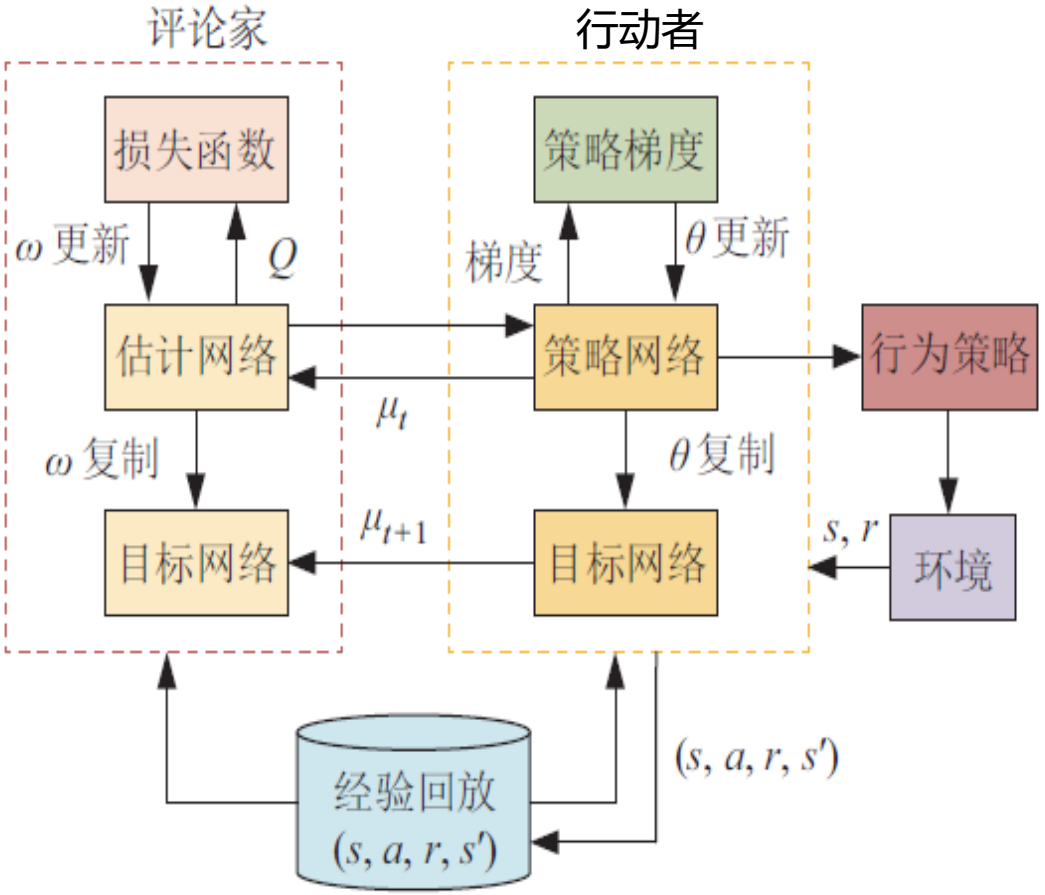


图 4 DDPG 算法结构示意图

典型深度强化学习算法

2、DDPG算法的改进

- 双延迟深度确定性策略梯度（twin delayed DDPG，TD3）算法

对DDPG 算法的优化包括三部分：采用双Q 网络的方式解决了评论家中Q 函数高估Q 值的问题；通过延迟行动者的策略更新使得行动者的训练更加稳定；利用目标策略平滑化的方法在行动者的目标网络计算Q 值的过程中加入噪声，使网络准确且鲁棒性强。

- MA-BDDPG （model-assisted bootstrappedDDPG）算法

将DDPG 算法中的经验池分为传统经验池和想像经验池，想像经验池数据来自动力学模型生成的随机想像转换。训练前，智能体计算当前状态行为序列Q 值的不确定性。Q 值的不确定性越大，则智能体从想像经验池中采集数据的概率越大。该方法通过扩充训练数据集显著加快了训练速度。

五、信赖域策略优化算法及其改进

1、TRPO算法

TRPO（trust region policy optimization）算法针对策略梯度算法中难以选择合适的更新步长的问题，对策略进行改善，使得回报函数单调递增。策略梯度算法中，神经网络直接输出策略函数，根据状态选择动作，在TRPO 算法中，回报函数定义为旧策略与新策略回报差之和。

TRPO 算法首先通过蒙特卡洛方法估计Q 值，然后根据平均Q 值得到目标和约束的估计，最后采用共轭梯度和线搜索方法近似解决约束优化问题。TRPO 算法保证了策略优化过程中性能渐进提高。但是，其计算量较大，并且策略与值函数之间参数不共享。

典型深度强化学习算法

2、TRPO算法的改进

- 近端策略优化（proximal policy optimization，PPO）算法

受 TRPO 启发提出的策略优化算法，采用 Actor–Critic（AC）架构，利用新旧策略的概率比，对同一批采集数据进行多轮更新，并通过裁剪目标函数抑制过大的策略变化，从而改善训练稳定性。已应用于机器人控制、游戏智能体，也曾广泛用于大模型的 RLHF 偏好对齐；是应用较广的深度强化学习算法之一，相对易于实现，具有较好的稳定性和通用性。

- ME-TRPO （modelensemble trust-region policy optimization）算法

采用集成神经网络解决环境中数据不稳定性的问题，并交替进行模型学习和策略学习，对复杂任务具有良好的适应性。

- SLBO（stochastic lower bound optimization）算法

相对于ME-TRPO 算法，保证了单调性的提高，并使用L2 范数损失函数训练动力学模型。少样本训练时，SLBO 算法在多项MuJoCo 仿真器任务中的性能优于SAC 算法、TRPO 算法等。

典型深度强化学习算法

六、其他深度强化学习算法

- **DreamerV3 算法**

基于世界模型的深度强化学习算法，主要解决稀疏奖励、多任务泛化难题。DreamerV3 学习环境隐空间动力学模型，在模型内部想象轨迹训练 Actor-Critic，仅用一套超参数适配离散、连续、视觉等多种任务，大幅提升样本利用率。

- **TD-MPC2 算法**

基于模型的深度强化学习算法，面向连续控制场景。TD-MPC2 学习隐式环境动力学模型，结合模型预测控制 MPC 做轨迹规划，不需要循环结构，在大量机器人控制任务上泛化性强。

- **CrossQ 算法**

无模型、离策略（off-policy）深度强化学习算法，针对连续控制优化。CrossQ 移除传统目标网络，借助批归一化稳定 Critic 训练，在低更新比下仍保持高样本效率，简化训练流程。

典型深度强化学习算法

- **RLPD（Reinforcement Learning with Prior Data）算法**

融合离线先验数据的离策略深度强化学习算法。RLPD 均衡采样离线演示数据与在线交互数据，基于 SAC 框架，利用已有先验数据加速机器人在线强化学习，降低真实环境交互成本。

- **GRPO（Group Relative Policy Optimization）算法**

面向大模型推理的深度强化学习算法，主要解决 PPO 需要价值网络、训练开销大的问题。GRPO 对同一个 prompt 采样多条回答，用组内奖励归一化估计优势，不需要独立 Critic，适合数学、代码推理任务。

- **RLOO（REINFORCE Leave-One-Out）算法**

基于 REINFORCE 的策略梯度强化学习算法。RLOO 采用留一法基线估计优势，降低梯度估计方差，实现简单，常用于大模型推理奖励微调。

- **DAPO（Decoupled Clip and Dynamic sAmpling Policy Optimization）算法**

面向长思维链大模型的强化学习算法，改进 GRPO。DAPO 将裁剪约束与采样过程解耦，引入动态采样机制，缓解长轨迹训练时的策略坍缩问题，提升长推理任务稳定性。

算法分析与理论--开篇

深度强化学习算法、应用与发展

01. 深度强化学习的概念

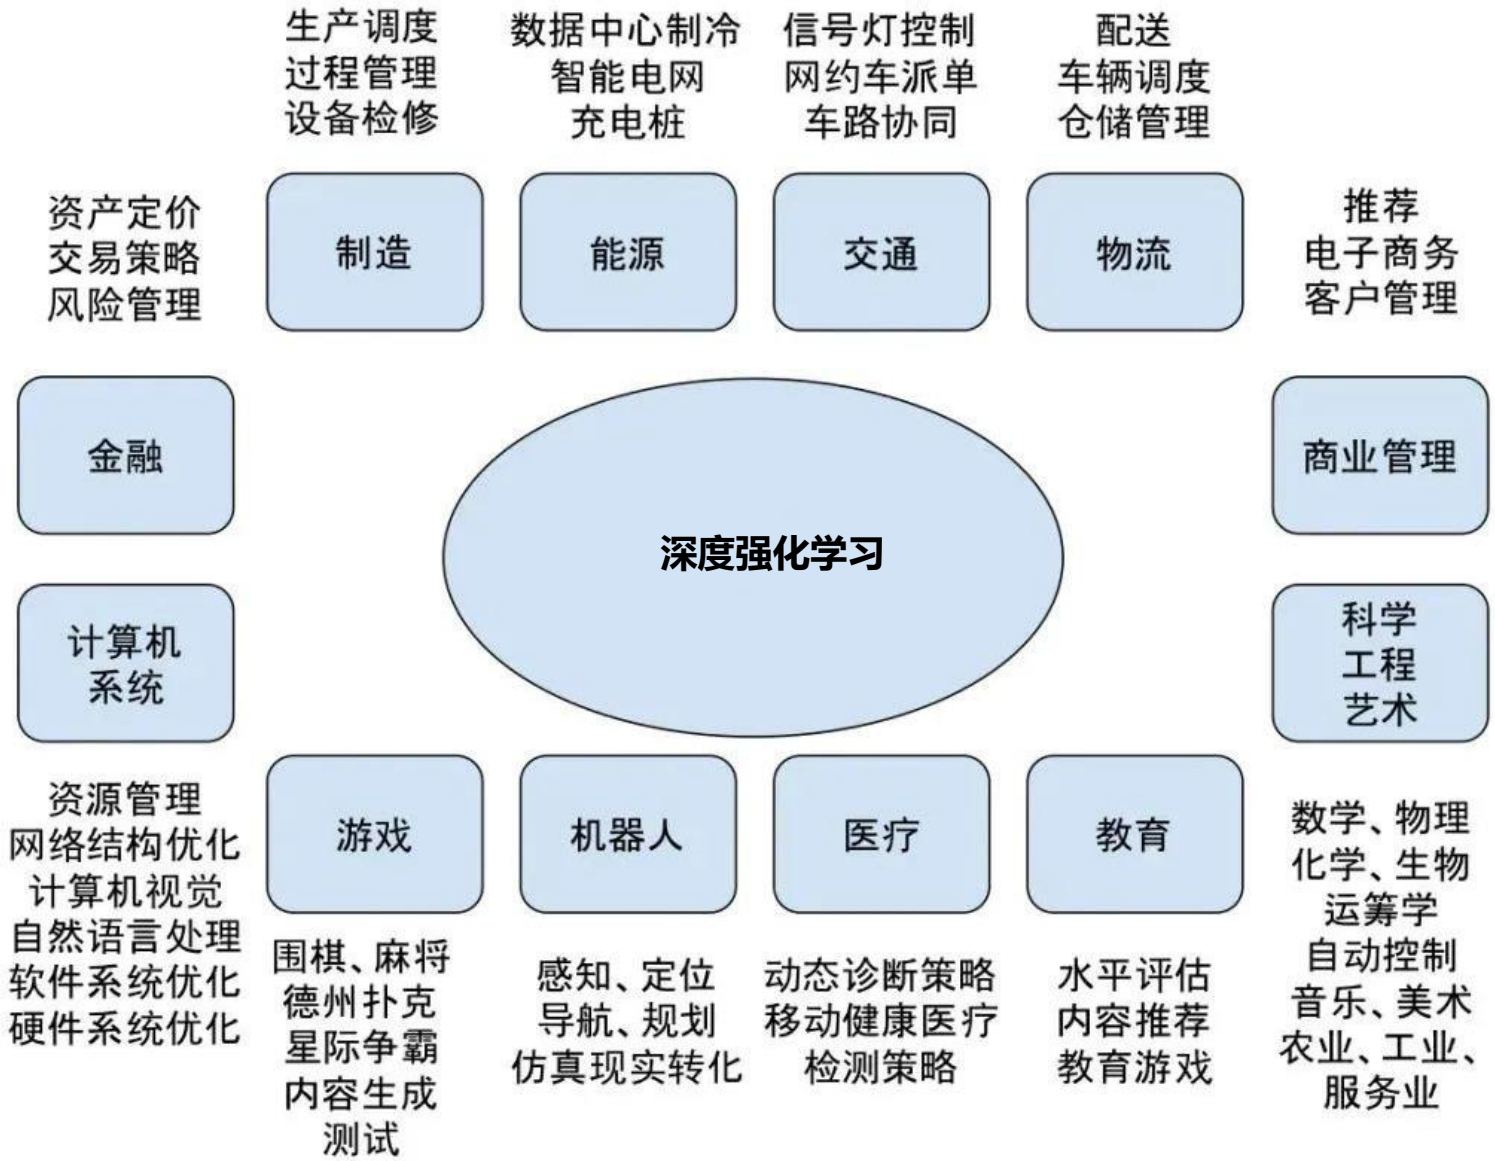
02. 各类深度强化学习算法

03. 深度强化学习算法应用

04. 深度强化学习算法发展

深度强化学习算法的应用

一、应用领域总览



深度强化学习算法的应用

二、游戏中的应用

强化学习的比重越来越大

AlphaGo的三个版本：

AlphaGo Lee---战胜李世石

AlphaGo Master---战胜柯洁

AlphaGo Zero---吊打前两代



深度强化学习算法的应用

三、自动驾驶中应用

自动驾驶是司机（agent）在环境（道路）的反馈下， 做出一系列决策的过程。这个过程非常符合强化学习模型的决策过程。

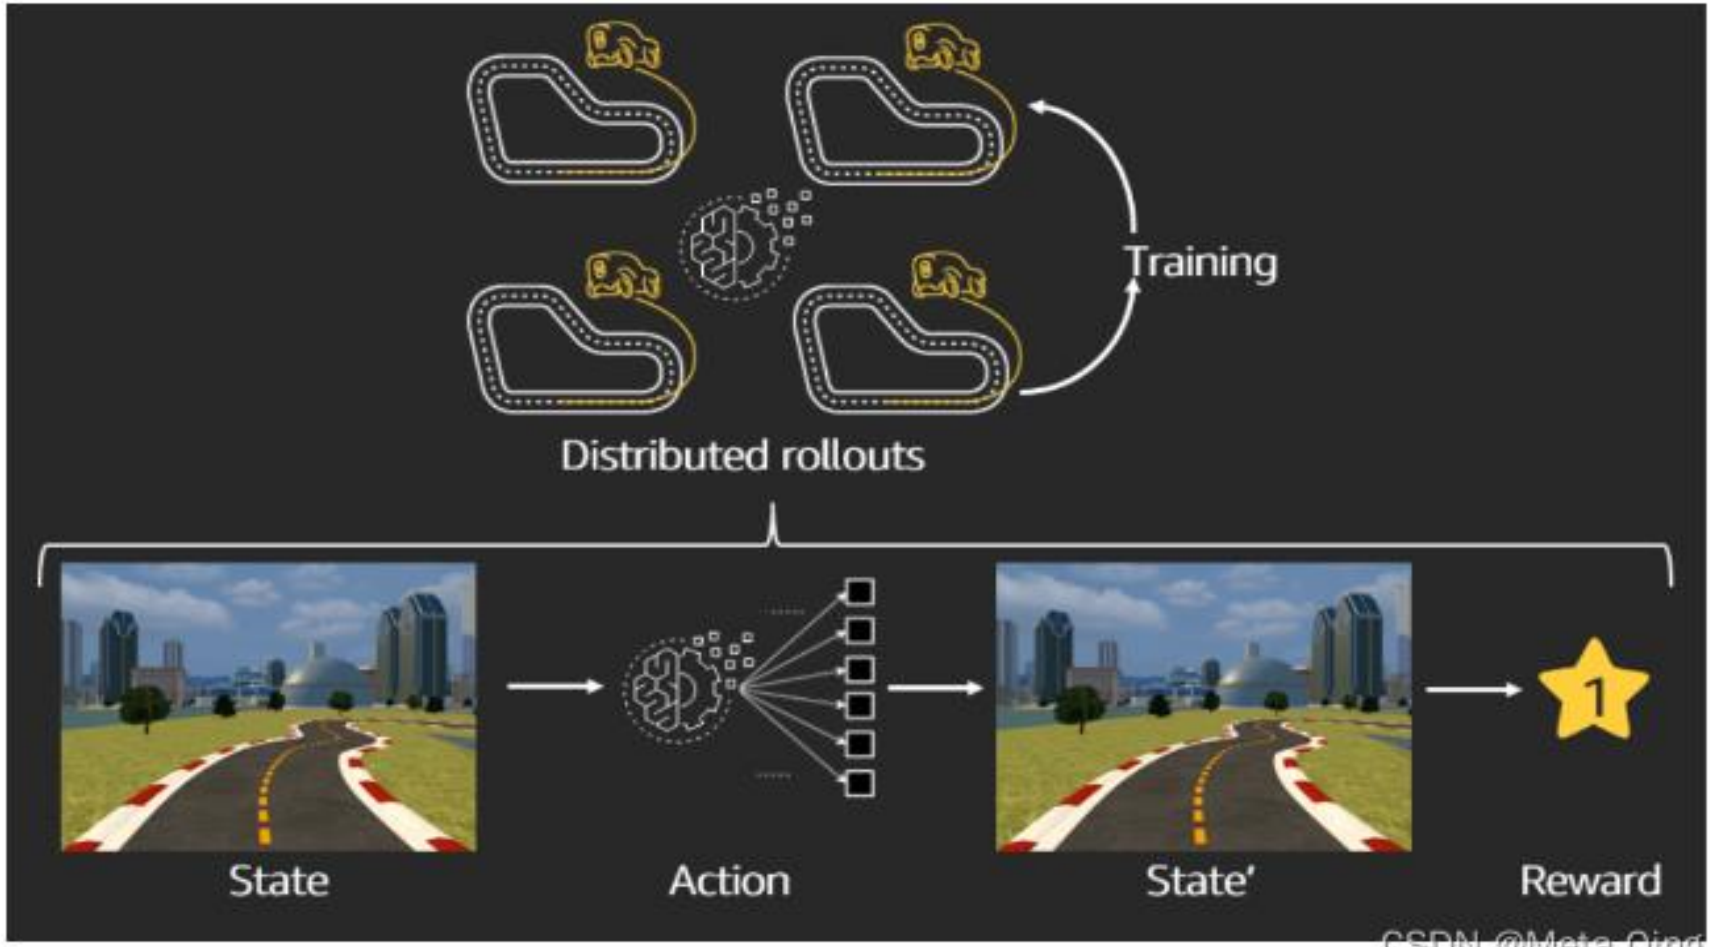
自动驾驶需要考虑的问题：不同地方的限速不同，是否是可行驶区域，如何躲避障碍等问题。

深度强化学习可以解决的问题：轨迹优化，运动规划，动态路径，最优控制，以及高速路中的情景学习策略。

目前自动驾驶大多属于L2级别（组合驾驶辅助）：可自动完成某些驾驶任务，并经过处理分析，自动调整车辆状态。

深度强化学习算法的应用

DeepTraffic是一个开源环境，它结合了强化学习、深度学习和计算机视觉的力量来构建由 MIT 推出的用于自动驾驶的算法。它模拟无人驾驶车辆，如无人机、汽车等。

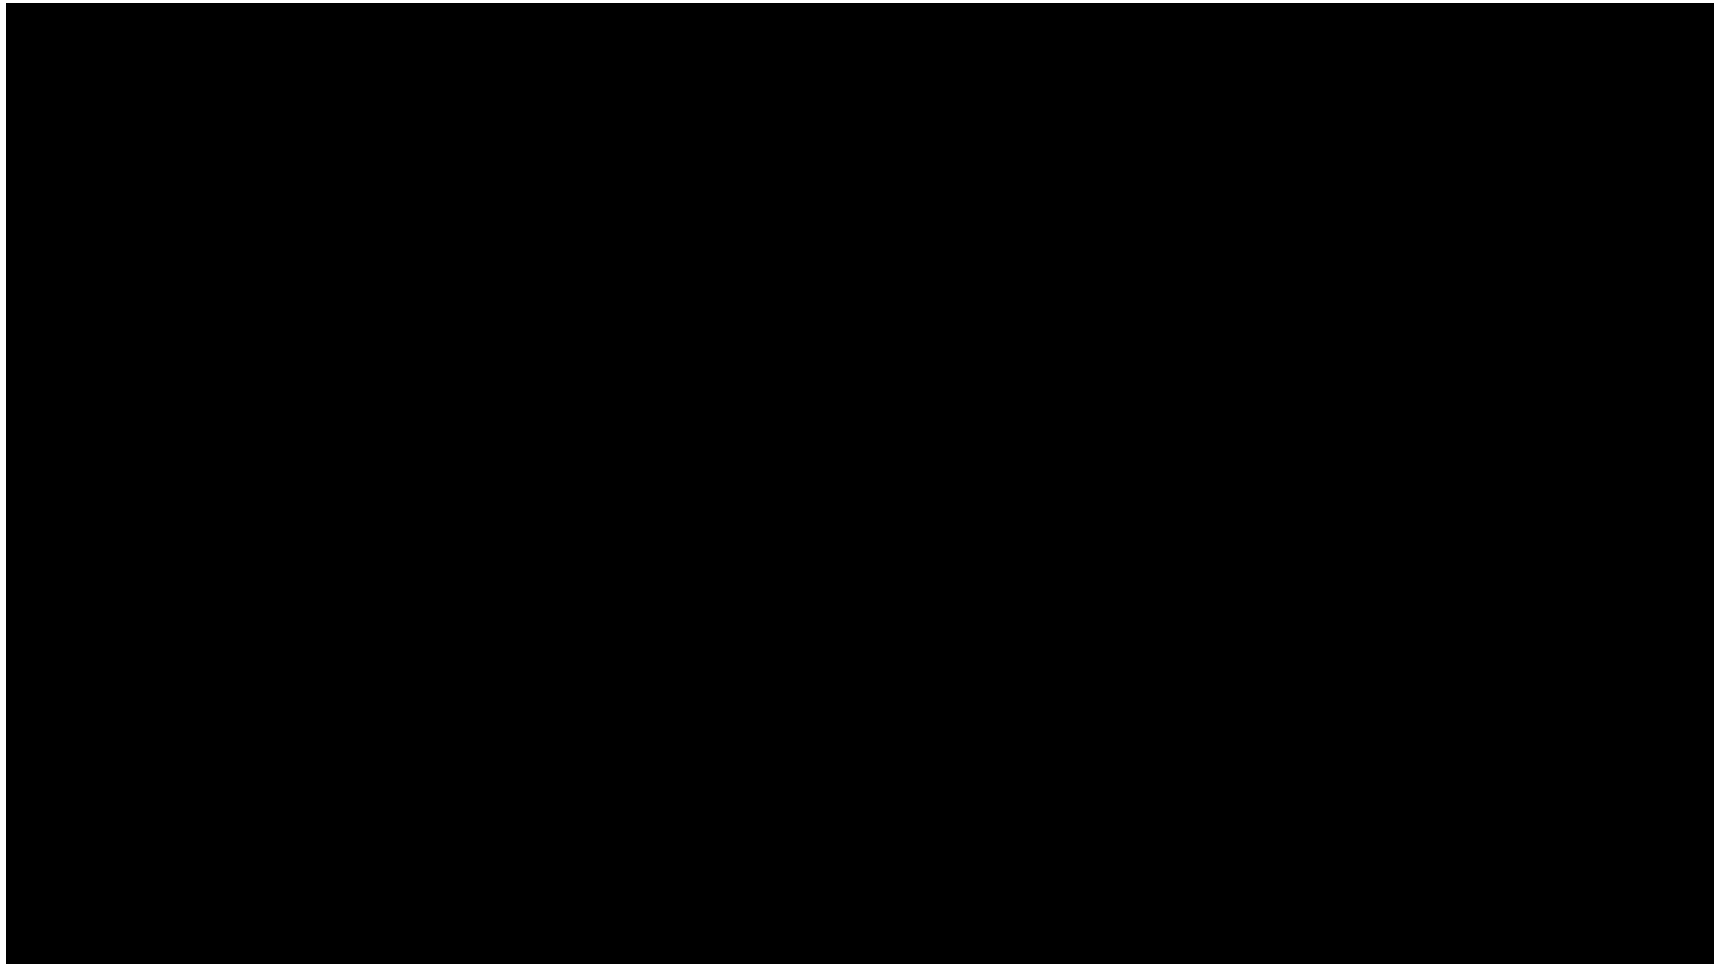


CSDN @Meta.Qing

自动驾驶汽车中的深度强化学习

深度强化学习算法的应用

利用强化学习算法学习驾驶



深度强化学习算法的应用

智能船舶路径规划---多智能体深度强化学习MAAC算法

MAAC（Actor-Attention-Critic for Multi-Agent Reinforcement Learning）算法

一种基于Actor-Critic框架的多智能体深度强化学习算法

针对环境是动态不稳定的问题

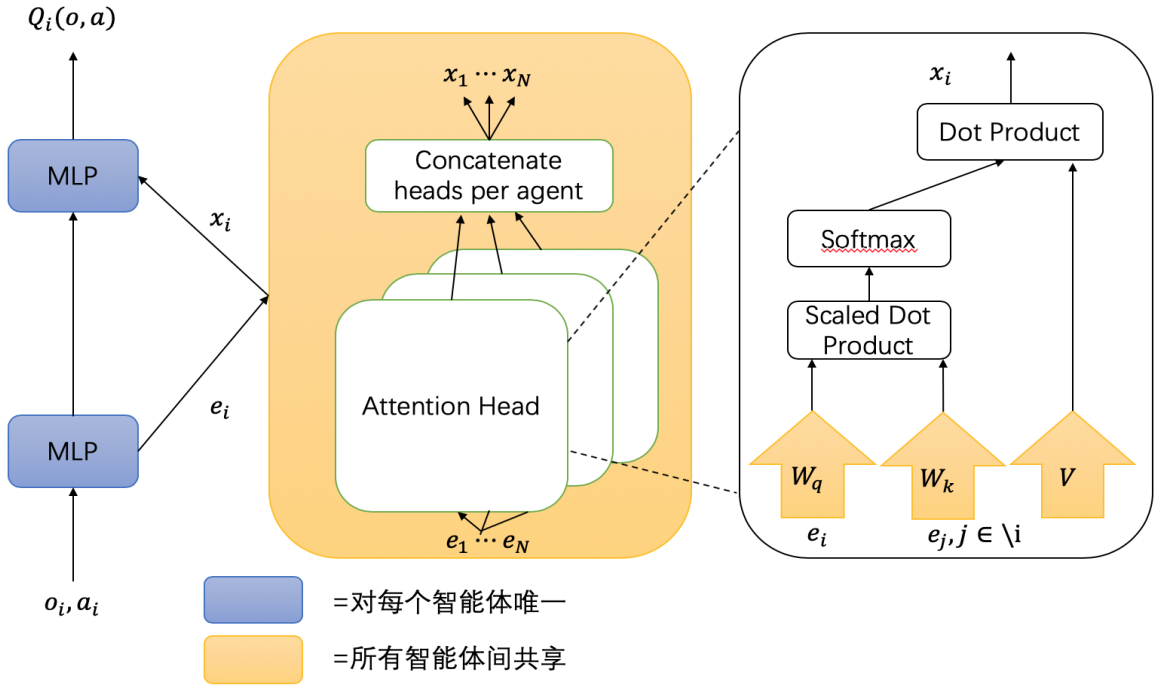
每个智能体在利用Actor做行为选择时只依据自身所观测到的信息进行决策。

针对复杂的多智能体环境中的性能问题

具有注意力机制的Critic框架，能够在训练期间的每个时间点动态地选择要关注的智能体。

深度强化学习算法的应用

多智能体深度强化学习MAAC算法



每个智能体向其他智能体查询关于它们的观察和操作的信息，并将这些信息合并到其值函数的估计中。

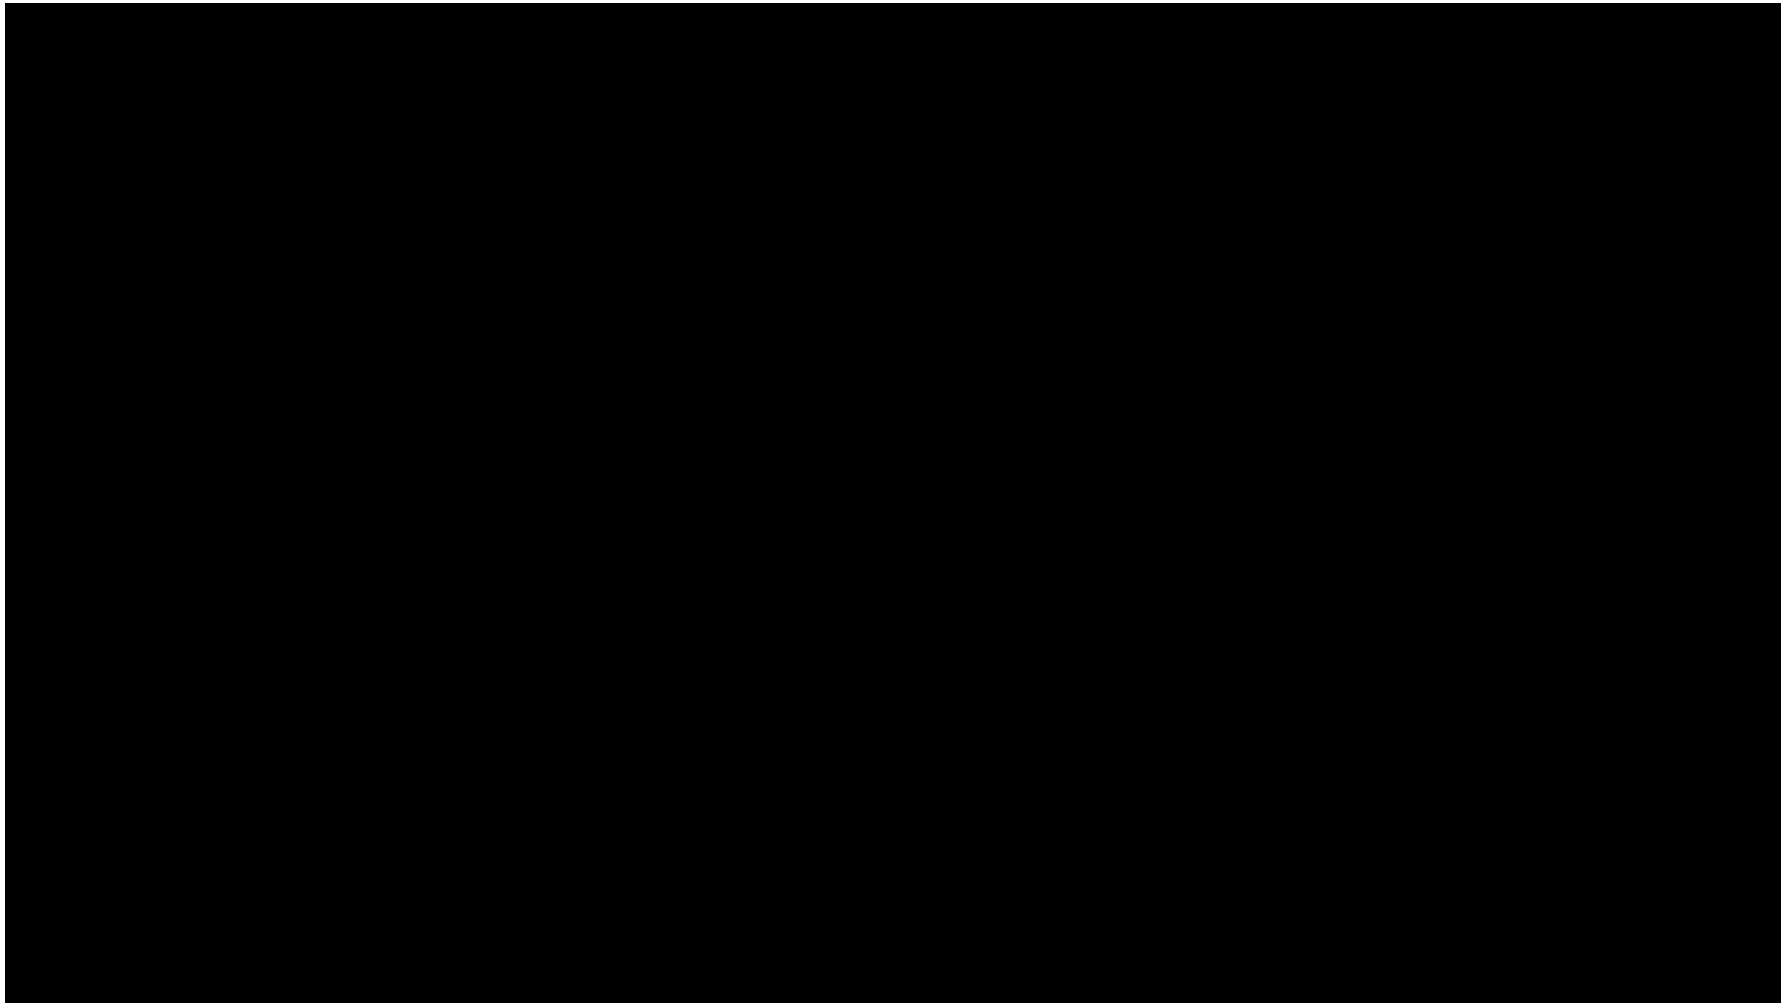
基于MAAC的多船协同避碰路径规划算法

（1）环境地图构建和参数设置

（2）路径规划模型训练

（3）生成规划的船舶路径

深度强化学习算法的应用



深度强化学习算法的应用

四、自然语言的应用：

覆盖文本摘要、问答、机器翻译、复杂推理与智能体任务

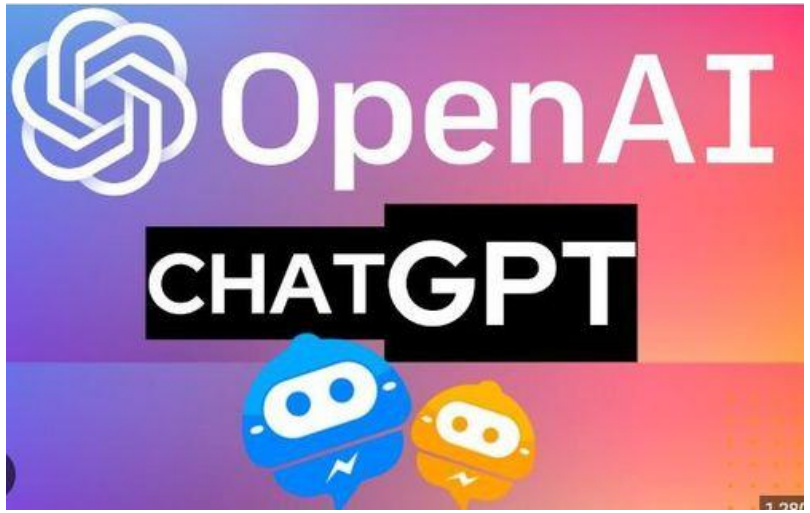
ChatGPT系列大模型---OpenAI 持续迭代的大语言模型产品矩阵，基于 Transformer 神经网络架构，**深度强化学习是其实现人类偏好对齐、提升复杂推理能力的核心技术底座**，具备跨模态理解与生成能力。核心功能：

1）**多轮自然对话**：基于上下文感知实现流畅的人机交互，支持长文本理解、复杂问题拆解与多轮连续追问；

2）**全链路代码生成**：从早期简单脚本生成，演进为覆盖代码生成、补全、调试、架构设计、漏洞修复的全流程开发支持；

3）跨模态内容生成：支持文本、图像、语音、视频的跨模态输入输出，可完成图文创作、视频脚本、实时语音交互等任务；

4）自主智能体能力：内置长程规划与工具调用能力，可自主完成数学证明、科研文献分析、网页操作等复杂任务。



深度强化学习算法的应用

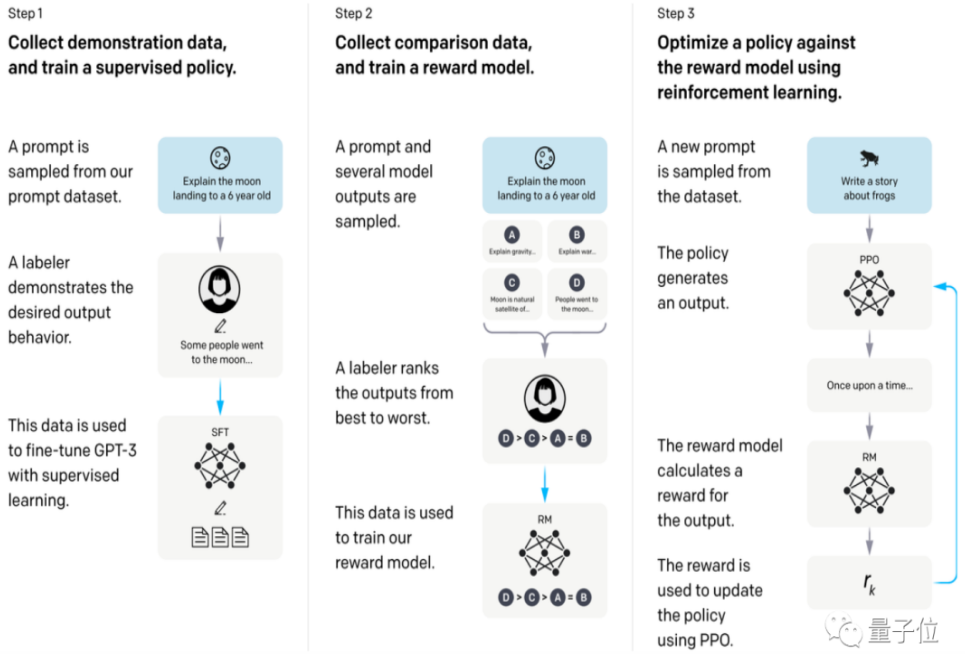
深度强化学习算法的应用：

大模型的强化学习对齐与训练流程

第一步，**监督微调（SFT）阶段**：使用人类标注的高质量演示数据，基于开源 / 闭源基座大模型进行指令微调，训练出具备基础对话能力的初始策略模型；

第二步，**奖励建模阶段**：收集相同提示下不同模型输出的排序反馈数据，训练奖励模型，量化评估回答质量、安全性与人类偏好匹配度；

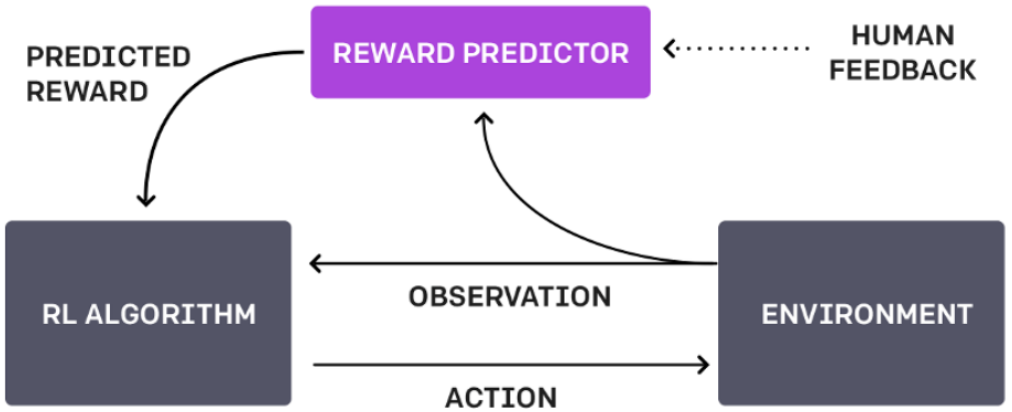
第三步，**策略优化阶段**：早期采用 PPO 强化学习算法完成微调，当前已**演进为 DPO、GRPO、DAPO 等新一代高效 RL 算法**，无需独立价值网络即可完成策略优化，大幅降低训练成本。



以上流程统称为 RLHF（reinforcement learning from human feedback 人类反馈强化学习）技术。

深度强化学习算法的应用

RLHF（reinforcement learning from human feedback）的思想最早在 2017 年 6 月 OpenAI 提出。其核心思想是利用人类反馈训练能解释人类判断的奖励函数，再通过强化学习训练策略完成目标对齐；当前技术体系已从早期的对话对齐，目前已拓展为面向数学、代码推理任务的 RLVR（可验证奖励强化学习），是大模型能力迭代的核心路径。



大模型能力突破的核心支撑

- 强大的基座大模型能力（覆盖 GPT、Gemini、DeepSeek 等多代主流模型）
- 大参数规模与高质量预训练语料（支撑长程理解与跨领域泛化）
- 高质量的反馈与可验证奖励数据（多轮对话偏好数据、数学 / 代码可验证样本）
- 性能稳定高效的深度强化学习算法（从早期 PPO 演进为 GRPO、DPO 等新一代 RL 算法）

深度强化学习算法的应用

五：自动化金融贸易

金融交易其实也是基于金融市场的一系列的决策过程， 很符合强化学习的范式。

通过强化学习，金融贸易不再像从前那样由分析师做出每一个决策，真正实现机器的自动决策。例如，IBM构建有一个强大的、面向金融交易的强化学习平台，该平台根据每一笔金融交易的损失或利润来调整奖励函数。



深度强化学习算法的应用

六：机器人技术

机器人在高度动态和不断变化的环境中运行，因此无法预测接下来会发生什么。强化学习在这些场景中提供了相当大的优势，使机器人足够健壮，并有助于在不同场景中自适应地获取复杂的行为。

- 机器人手术

手术机器人可以最大限度地减少错误和任何变化，并最终帮助提高外科医生的效率。达芬奇就是这样一种机器人，它允许外科医生以比传统方法更大的灵活性和可控性来执行复杂的手术。

- 工业机器人---缺陷检查

使用多模态数据训练深度强化学习模型，以轻松识别缺失的部分、凹痕、裂缝、划痕和整体损坏，图像跨越数百万个数据点。

深度强化学习算法的应用

机器人学习避碰

深度强化学习的不足

1.样本利用率非常低；---为了让模型的表现达到一定高度，需要极为大量的训练样本

2.最终表现很多时候不够好；

3.好的奖励函数难以设计；---有时候把奖励乘以一个常数模型表现就会有天和地的区别

4.难以平衡“探索”和“利用”，以致算法陷入局部极小；

5.对环境的过拟合；---DRL 少有在多个环境上玩得转的。

6.灾难性的不稳定性。

算法分析与理论--开篇

深度强化学习算法、应用与发展

01. 深度强化学习的概念

02. 各类深度强化学习算法

03. 深度强化学习算法应用

04. 深度强化学习算法发展

多智能体深度强化学习

一：多智能体深度强化学习相关概念

- 多智能体系统（Multi-Agent System，MAS）：是在同一个环境中由多个交互智能体组成的系统，该系统常用于解决独立智能体以及单层系统难以解决的问题，其中的智能可以由方法、函数、过程，算法或强化学习实现；

- 多智能体深度强化学习：将DRL方法融入到MAS中，依托深度强化学习在未知环境中的序贯决策能力，融合了运筹学、博弈论和群体心理学等众多学科，能够更好地发挥多个智能体的协同优势，进而低成本、高效率地完成复杂任务。

- 基本框架结构：

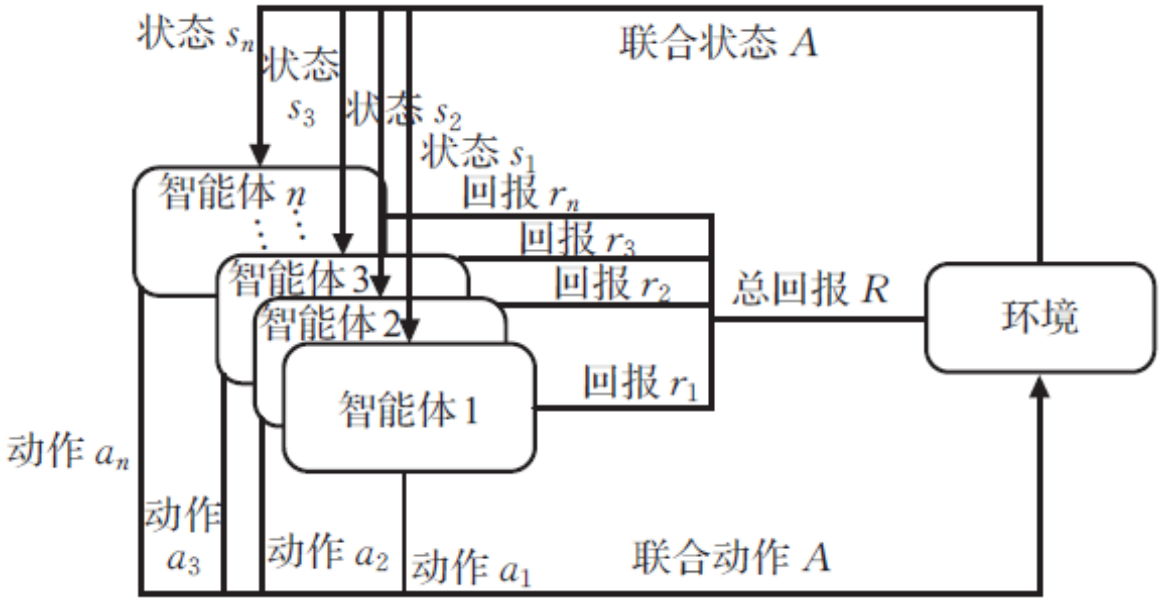


图2　多智能体强化学习基本框架

二：多智能体深度强化学习研究方法

1、无关联型多智能体深度强化学习

此类方法并不从算法创新本身入手，而是将单智能体DRL 算法直接扩展到多智能体环境中，每个智能体独立地与环境进行交互并自发地形成行为策略，互相之间不存在通信关联，其最初多用于测试单智能体DRL方法在多智能体环境中的适应性。

表2 无关联型方法总结分析

研究者	完成工作	性能特点
Tampuu/Leibo/Peysakhovich	将DQN等算法应用到简单游戏场景中	完成合作、竞争、混合型多种任务
Bansal等	将PPO算法应用到MuJoCo环境中	引入探索回报和对手采样机制，产生较优策略
Raghu等	使用DQN/A3C/PPO等算法解决零和博弈问题	可以形成多种不同策略
Gupta等	将DQN/TRPO/DDPG等算法应用到复杂多智能体环境中	引入参数共享和课程学习机制，结合RNN，具有较强可扩展性

2、通信规则型多智能体深度强化学习

此类方法在智能体间建立显式的通信机制（如通信方式、通信时间、通信对象等），并在学习过程中逐渐确定和完善该通信机制，训练结束后，每个智能体需要根据其他智能体所传递的信息进行行为决策，此类方法多应用于完全合作型任务和非完全观测环境。

表3 通信规则型方法总结分析

算法名称	通信方式	优点	缺点
RIAL/DIAL	使用中心化的 Q 网络和通信通道在智能体之间进行信息传递	通信模型十分简化，实现了智能体间基本的通信，后者还能实现双向通信	只能传递离散化的信息，无法实现复杂信息传递
CommNet	在智能体之间构建了一个具备传输连续信息能力的通信通道	可在智能体之间进行连续信息通信，智能体可以自由选择通信时间和范围	集中式训练模式，复杂度较高，容易维度爆炸，可扩展性差
BiCNet	使用AC框架和双向循环神经网络共享信息实现通信	实现了异构智能体间的即时通信，可对星际争霸2中多个单位进行复杂配合的控制	专门为特定应用设计，方法泛化能力有限
ATOC/Schedule Communication等	采用注意力机制通信和规划通信模型	对信息传递的模式进行了优化，智能体实现了全时段通信能力	模型复杂度较高，针对特定场景和应用，不具泛化性

多智能体深度强化学习

3、互相协作型多智能体深度强化学习

此类方法并不直接在多智能体间建立显式的通信规则，而是使用传统多智能体深度强化学习中的一些理论使智能体学习到合作型策略。

表4　互相协作型方法总结分析

算法名称	主要机制	优点	缺点
VDN/QMIX/QTRAN等	采用值函数分解思想，按照智能体对环境的联合回报的贡献大小分解全局Q函数	很好地解决了多智能体信度分配问题	目前不存在一种有效的分解机制对多智能体环境具有普适性，分解方法较为单一，如线性分解、矩阵分解等方式
MADDPG	采用AC框架和集中训练分散执行模式，每个智能体拥有中心化的Critic接受全局信息	无需建立现实通信规则，很好地解决了环境非平稳性问题，算法容易收敛至全局最优解	可扩展性差，不支持大量智能体训练，训练周期较长
COMA	采取完全集中的训练方式，算法中引入反事实基线概念，面向合作型任务	解决多智能体环境中的非平稳性问题，不受环境改变的影响	可扩展性较差，集中式训练器容易维度爆炸，对参数要求较高
PS-DQN/PS-DDPG/PS-TRPO等	将参数共享机制融入DRL算法	提升算法的训练效率和收敛速度	不适用异构型智能体的合作，只支持智能体完成较为简单的任务
WDDQN	将双Q网络结构和宽大回报理论引入DQN	解决了多智能体环境下的过估计问题，提升了随机策略更新能力	算法对数据和参数要求较高，对环境适应性不强

多智能体深度强化学习

4、建模学习型多智能体深度强化学习

该方法旨在对手或队友策略不可知的情况下以智能体建模的方式对行为进行预测，这类算法一般鲁棒性较强，可以应对多种不同的场景，但计算和建模的复杂度较高，无法适应大型复杂的多智能体系统，所以实际应用较少。

表5　建模学习型方法总结分析

算法名称	主要机制	适用场景
DRON	采用独立的神经网络学习对手智能体的策略	混合型场景
DPIQN	根据其他智能体观测进行建模，通过附属任务学习智能体策略	多子任务的对抗型场景
SOM	使用自身策略预测其他智能体的行为	多目标合作型场景
NFSP	双网络模拟智能体互博弈过程，通过找到纳什均衡完成算法收敛	棋牌类游戏等不完美信息的完全竞争场景
M3DDPG	改进自经典MDRL算法MADDPG，引入Minimax原则对环境中敌对智能体进行最坏估计，提升了生成策略的鲁棒性	混合型场景中强鲁棒策略的生成

多智能体深度强化学习

表6 多智能体强化学习方法分类对比分析

方法分类	优点	缺点
无关联方法	简单,易实现	无法解决多智能体环境的非平稳性问题,难稳定收敛
通信规则型方法	建立的显式信道,学习最优策略	参数较多,算法的设计架构较为复杂
互相协作型方法	无需通信建模,兼具易实现性和高效性,通用性强	应用环境单一(无法应对完全竞争型环境)
建模学习型方法	可预测其他智能体行为,鲁棒性强,适用不同场景	计算复杂度高,无法适用大型系统

元强化学习

一：元强化学习相关概念

- 元学习：又称学会如何学习，旨在借助先前的经验知识学习如何学习，利用学习所得的先前经验提高未来的学习表现，使其在未来学习中减少样本数量的需求。其目标是训练一个模型，该模型只需要几个数据点和几次训练迭代就可以快速适应新的任务。
- 元强化学习算法(metareinforcementlearning，MetaRL)：简而言之就是将元学习应用于强化学习，从一组相关任务中学习有用的元知识，智能体获得学会学习的能力，从而提高在新任务上的学习速度，降低样本复杂度。
- 解决强化学习的问题：重点关注强化学习训练样本需求多、训练速度慢、迁移效果差的问题，即如何使用少量样本快速学习新任务是强化学习中亟需解决的问题。

深度强化学习算法发展

- 元强化学习结构：内、外循环

  ✓ 内循环阶段：智能体利用外循环所提供的元知识进行强化学习，对元知识质量进行评估后反馈给外循环；

  ✓ 外循环阶段，从相关任务中学习元知识，根据来自内循环的反馈对元知识进行调整。外循环使用从相关任务中积累的元知识对内循环进行指导，使内循环可以快速调整以适应新任务。

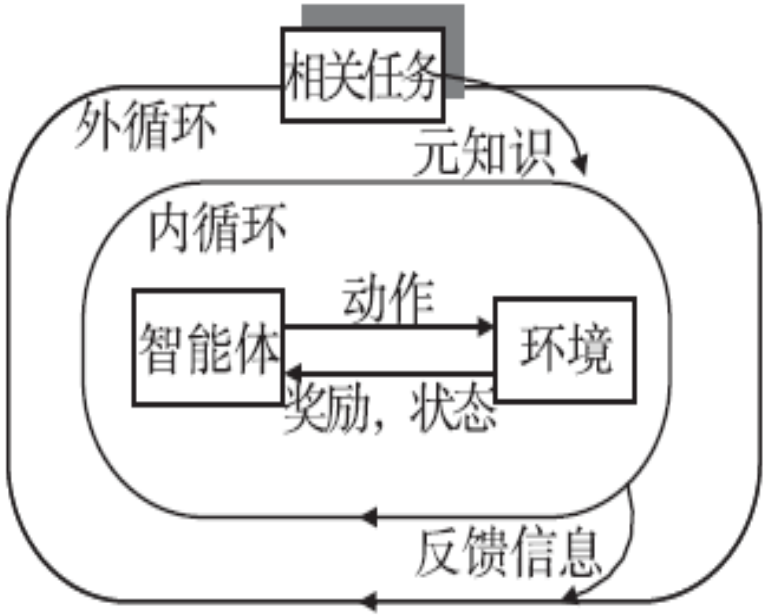


图 1　元强化学习基本框架

元强化学习

二：元强化学习研究方法

1、基于循环网络的元强化学习

该类元强化学习算法利用RNN学习元知识，学习到的先前经验以网络参数的形式表示并存储在网络上，训练好的网络模型可以借助网络存储的知识快速适应新任务。

表 1　基于循环网络的元强化学习算法对比汇总

Tab. 1　Comparison of meta reinforcement learning algorithms based on RNN

算法	优点	缺点
LSTM A2C/A3C[25]	引入 RNN，在每次输入时馈入历史信息	性能受限于新任务与训练任务接近程度[35]
RL^2[28]	策略使用 RNN 结构	难以对大量样本信息快速编码
E-RL^2[29]	提高了 RL^2 的探索潜力	探索过程中策略可能会选择无即时回报的动作
RBAC[30]	结合 MPC 实现在线自适应，提高了适应能力	额外添加了模型参数和更新规则参数
MANN[32]	利用外部记忆模块存储元知识，结合长期和短期记忆	权重更新速度缓慢
LSTM-Optimizer[33]	LSTM 优化器避免了人工设计环节	优化过程复杂
LSTM-based meta-learning[34]	使用 LSTM 代替梯度下降，适应少样本情况	优化成本高，花费时间长

元强化学习

2、基于上下文的元强化学习

该类方法使用上下文(context)来估计隐藏的任务嵌入实现快速适应。为解决元知识质量和泛化能力低的问题，上下文作为一种从先前经验中获得的元知识，提供相关任务的特征信息，通过将经验聚合成隐藏表征实现快速适应，合理利用了先前经验并提高了学习速度和泛化能力。除此之外，为解决探索能力有限的问题，该类元强化学习方法在应用上下文的基础上还通过解耦探索和利用、改进探索目标等方法，实现了对探索策略的优化。该方法已经被证明是一个性能优越的结构，基础的强化学习算法(如TD3）与上下文相结合后性能可以达到最先进的元强化学习算法的水平。

表2　基于上下文的元强化学习算法对比汇总
Tab. 2　Comparison of meta reinforcement learning algorithms based on context

算法	优点	缺点
SNAIL[38]	软注意力机制实现精确查找，更容易训练	处理长序列时卷积层数过多
PEARL[40]	采用概率上下文推断任务不确定性，样本效率高	元过渡拟合，任务推理中训练和测试数据不匹配[47]
MIER[35]	有效适应训练任务分布外的任务	需要先验知识
HTR[45]	结合后经验重标记克服了稀疏奖励环境中学习的困难	增加了需要优化的超参数
CASTER[47]	优化了任务探索能力，缓解了元过渡拟合	算法结构复杂
CAVIA[48]	改善过拟合问题，更容易并行化，对学习率有鲁棒性	需要计算高阶梯度，计算规模大[48]
MQL[36]	重用回放缓冲区中的数据，提高了样本效率	要求在自适应期间访问回放缓冲区，添加额外超参数
PEMIRL[50]	扩展性强，奖励函数鲁棒性高	计算复杂，添加了额外待更新参数
DREAM[53]	解耦探索和利用，解决了局部最优的问题	添加了三个额外超参数
MetaCURE[54]	减少不确定性探索，解决奖励稀疏问题	算法复杂，添加额外超参数
CCM[55]	提高了上下文质量	添加了额外参数

元强化学习

3 基于梯度的元强化学习算法

针对强化学习泛化能力低和学习速率慢的问题，梯度下降法作为常用的优化方法被应用于元强化学习中， 经梯度下降优化后，在解决新任务时可以仅通过少数步骤的梯度变换实现快速适应新任务，提高了通用性，节省了时间成本。另外，在本类算法中，同样也对探索问题进行了解决，通过添加探索项、设计独立探索策略等方法增添智能体的探索潜力和激发探索新状态的能力。

表 3　基于梯度的元强化学习算法对比汇总

Tab. 3　Comparison of meta reinforcement learning algorithms based on gradient

算法	优点	缺点
Meta-Gradient RL[59]	自动更新超参数，在线调整选择最优超参数	参数更新速度较慢
HD[60]	减少了调整初始学习率花费的时间和数据	理论收敛保证的起步条件有限
MAML[61]	适合任何基于梯度的模型，通用性强	二级梯度计算复杂性高，过拟合问题
Reptile[62]	无须划分训练和测试，算法简单，避免了二阶梯度	对内循环超参数不敏感
SG-MRL[63]	为模型无关元强化学习算法提供了收敛保证	要求梯度范数有界，仅限于实现一阶最优性
ProMP[64]	结合近端策略优化和低方差曲率解决了信度分配问题	无法在稀疏奖励条件下使用[54]
GMPS[65]	引入有监督的模仿学习，最多可减少 10 倍的样本量	元训练任务数量多时不易对其全部进行训练
ES-MAML[66]	避免了估计二阶导数，算法简单	恒定步长影响实验结果
E-MAML[29]	在 MAML 中添加探索项，提供了更多探索机会	依赖特定任务的采样轨迹，信度分配混乱
MURAL[68]	激励探索新状态，提供奖励塑造而无须手动调整奖励	需要额外提供任务成功案例
MAME[70]	为任务分布设计独立探索策略，稳定性和渐进性能高	对稀疏奖励任务无效[54]
MAESN[71]	引入与时间相关的噪声改进探索策略实现结构化探索	仅适用于训练期间获得密集奖励情况[54]
Learning to explore[72]	引入元策略梯度改进探索策略，实现全局探索	仅适用于异策 RL
EPG[73]	利用 ES 优化损失函数，学习到的损失增加探索潜力	牺牲通用性以提高性能，计算规模大，成本高[74]
MetaGenRL[74]	结合多个智能体的经验，目标函数通用性强	二阶梯度不稳定，计算规模大
ML^3[75]	学习元损失函数的优化速度高于直接学习任务损失	损失函数从单一任务分布中获得，泛化性有限[74]
LPG[76]	良好的通用性，有效防止过拟合	超参数在新环境中需手动选择参数

元强化学习

4 基于分层的元强化学习算法

分层的思想本质在于将难以解决的主任务分解成不同层次上可有效解决的子任务，通过加快子任务的求解速度以加快对整体任务的解决速度。针对元知识的生成方法问题，基于分层的元强化学习算法使用分层思想对网络进行分层以应对要解决的一系列相关问题，底层网络在相关任务上学习并将从各任务中所学的知识向上传递给高层网络，高层网络学习传递上来的先前经验，整合任务间的共享知识得到元知识，完成任务的快速适应。

表4　基于分层的元强化学习算法对比汇总

Tab.4　Comparison of hierarchical meta reinforcement learning algorithms

算法	优点	缺点
MetaNet[77]	利用损失梯度作为元信息，模型结构灵活	快权重和慢权重的整合存在问题
MLSH[78]	共享信息用一组子策略模型，提高了学习速度	需要更新多个子策略参数
FRL[79]	有助于处理信度分配和长期记忆的任务	状态输入非结构化，控制器不适合横向传输
Meta-Critic[81]	任务行为编码器表示任务特征，鲁棒性高	网络中待估参数多，计算复杂
HAC[82]	端到端方法，适用于稀疏奖励环境	网络中待估参数多
MGHRL[85]	有效适应差距较大的新任务	算法复杂度高，网络结构复杂

元强化学习

5、离线元强化学习

为了解决元强化学习中落地难、实用性差的问题，通过利用大量预先收集的静态数据或离线数据集进行预训练，降低环境影响。与标准元强化学习不同，离线元强化学习在元训练期间无须与环境交互产生数据，消除了元训练期间的不安全探索行为和高成本的数据采集行为。

表5　离线元强化学习算法对比汇总

Tab.5　Comparison of offline meta reinforcement learning algorithms

算法	优点	缺点
FOCAL[86]	具有高效的任务推断，计算效率高，实用性强	前提假设条件在稀疏奖励和基于记忆的任务中不成立
BORel[87]	学习数据收集策略，解决了离线 MDP 的模糊问题	前提假设条件在离线环境中很难达成
MESA[89]	学习风险度量，保证安全学习	需要有足够多的数据了解测试环境中的约束
MACAW[90]	提高了样本效率，保证了元训练和元测试的一致性	额外引入了多个超参数

元强化学习

表 6　不同类型元强化学习对比分析

Tab. 6　Comparison of five types of meta-reinforcement learning algorithms

类型	优势	局限性
基于循环网络的元强化学习算法	架构设计简单易实现，RNN 结构保留历史记忆	探索能力弱，收敛不稳定
基于上下文的元强化学习算法	上下文结构功能强大，提供相关任务特征信息，样本利用率高，适应速度快，可进行任务推断，扩展性好	上下文质量难以保证，泛化性低，不适用基于记忆的任务
基于梯度的元强化学习算法	简单易实现，可扩展性高，适用范围广，泛化能力强，通用性高	二阶梯度的计算复杂度高且耗费时间长，难以应用于大规模问题
基于分层的元强化学习算法	分层思想划分不同模块以解决不同问题，根据问题类型灵活设计分层结构，算法表达性强	模型较大且复杂，参数多，鲁棒性低，样本需求量大，需要手动设计分层结构
离线元强化学习算法	避免了高成本的收集数据行为和危险的探索行为，安全性高，样本效率高	无法探索，依赖数据集的规模和质量，数据集的质量无法保证

深度分层强化学习

- 深度分层强化学习：其核心思想在于，根据分层思想构建具有多层结构的强化学习策略，运用时序抽象表达方法组合时间细粒度的下层动作，学习时间粗粒度的、有语义的上层动作，将复杂问题分解为数个简单问题进行求解。
- 解决强化学习的问题：重点关注经典深度强化学习难以解决的稀疏奖励、顺序决策和弱迁移能力等问题.

- 分类：
  - ✓ **基于技能的深度分层强化学习**：下层网络学习一组技能，然后由上层网络调用这些技能，使用不同的组合技能来解决下游任务;
  - ✓ **基于子目标的深度分层强化学习**：利用神经网络提取状态特征，然后将状态特征作为子目标空间.上层网络学习产生子目标，下层网络根据内部驱动来实现子目标.

深度分层强化学习

- 基于技能的深度分层强化学习框架
  - 同步式技能的深度分层强化学习
    - 独立型技能
    - 共享型技能
  - 异步式技能的深度分层强化学习
    - 技能学习
    - 技能组合
- 基于子目标的深度分层强化学习框架
  - 先见子目标的深度分层强化学习
  - 后见子目标的深度分层强化学习

潜在发展方向

- **样本效率**：**当前的深度强化学习方法通常需要大量的交互样本来学习有效的策略**，这在很多实际应用中是不可接受的。未来的研究可能会更加关注如何提高样本效率，例如通过更好的探索策略，或者使用模型的方法。

- **可解释性和可信赖性**：深度强化学习模型通常是“黑箱”，很难理解它们的决策过程。未来的研究可能会更加关注如何提高模型的可解释性和可信赖性，这对于许多安全关键的应用，例如自动驾驶和医疗诊断，是非常重要的。

- **多任务学习和迁移学习**：在许多实际的情况中，智能体需要在多个任务之间进行切换，或者将在一个任务中学到的知识应用到另一个任务中。如何有效地进行多任务学习和迁移学习仍然是深度强化学习的一个重要研究方向。

谢 谢!